

---

**Modelización y análisis de la respuesta inmune ante  
infecciones agudas**  
**Modelling and analysis of the immune response to acute  
infections**

---



**Trabajo de Fin de Grado**  
**Curso 2019–2020**

**Autor**  
**Belén Serrano Antón**

**Director**  
**Miguel Ángel Herrero García**

**Doble Grado en Ingeniería Informática y Matemáticas**  
**Facultad de Matemáticas**  
**Universidad Complutense de Madrid**

**1 de julio de 2020**



Modelización y análisis de la respuesta  
inmune ante infecciones agudas  
Modelling and analysis of the immune  
response to acute infections

Trabajo de Fin de Grado en Matemáticas  
Departamento de Análisis Matemático y Matemática Aplicada

**Autor**  
Belén Serrano Antón

**Director**  
Miguel Ángel Herrero García

**Convocatoria:** *Julio 2020*

Doble Grado en Ingeniería Informática y Matemáticas  
Facultad de Matemáticas  
Universidad Complutense de Madrid

1 de julio de 2020



*A mis padres y a mi gato Jimmy*



# Agradecimientos

A Miguel Ángel Herrero García, por su tiempo, su siempre buena disposición y por guiarme a lo largo de este proyecto.

También quiero agradecer a Clemente Fernández Arias, por acompañarnos en numerosas reuniones y por sus aclaraciones no solo sobre aspectos biológicos, sino también sobre cuestiones técnicas de los modelos. Sin duda alguna estas han sido claves para el desarrollo de este trabajo.





# Resumen

Nuestro sistema inmune es esencial para nuestra supervivencia. Sin él estaríamos expuestos a ataques de bacterias, virus y parásitos. Este sistema actúa por todo el cuerpo e involucra a muchos tipos de células. Su misión principal es reconocer patógenos y combatirlos, dando lugar a un proceso que llamamos respuesta inmune.

En lo que sigue nos centraremos en la dinámica de la población de un tipo de célula inmune concreto: las células T. Estas participan de manera fundamental en la respuesta inmune, pues se encargan de eliminar aquellas células del organismo que han sido infectadas. A día de hoy, los mecanismos biológicos que determinan cuándo y cuánto se reproducen estas células durante la respuesta inmune son conocidos solo de forma parcial.

A lo largo de este documento, se exponen dos modelos matemáticos, basados en ecuaciones diferenciales, que intentan dar una posible explicación a algunos aspectos de la respuesta inmune desde puntos de vista distintos: uno microscópico (a nivel celular) y otro macroscópico (a nivel de toda la población de células). Veremos que la actividad de las células T depende de su decisión entre división o suicidio (apoptosis) y esta decisión puede estudiarse por medio de ecuaciones simples, que permiten formular el problema de manera adecuada para su posterior análisis. Además del marco teórico de los modelos, se incluyen diversas simulaciones de los mismos. En ellas se pone de manifiesto su carácter flexible, pues permiten representar situaciones inmunológicas distintas cambiando valor de sus parámetros. De este modo es posible obtener información relevante sin necesidad de nuevos experimentos en un laboratorio. Además, en este trabajo se ha buscado una posible correlación entre los parámetros de los modelos (microscópico y macroscópico) propuestos. En concreto y como primera aproximación, se ha implementado una red neuronal que permite inferir los parámetros del modelo macroscópico teniendo como entrada aspectos característicos de una respuesta inmune.

## Palabras clave

modelos matemáticos, ecuaciones diferenciales, células T, patógenos, respuesta inmune, simulaciones numéricas.



# Abstract

Our immune system is essential to our survival. Without it, we would be defenceless to attacks from bacteria, viruses and parasites. This system acts throughout the body and involves many types of cells. Its main mission is to recognize pathogens and fight them, giving rise to a process called immune response.

In what follows, we will focus on the population dynamics of a particular type of immune cell: T cells. These cells play a fundamental role in the immune response, as they are active at eliminating those cells in the body that have been infected. The biological mechanisms that determine when and how much these cells reproduce during the immune response have not been fully elucidated yet.

In this document, two mathematical models based on differential equations are presented. They provide a possible explanation to some aspects of immune response from different points of view: one microscopic (at the cellular level) and the other macroscopic (at the level of the entire cell population). We will see that the activity of T cells depends on their decision between cell division or suicide (apoptosis) and that this decision can be studied by means of simple equations, which allow us to formulate the problem in a suitable form for later analysis. In addition to their theoretical framework, several simulations of the models are included. These show their flexible nature, as they allow different situations to be represented simply by changing parameter values in the corresponding equations. This allows for significant information to be inferred without the need for new experiments in a laboratory. Furthermore, a possible correlation between the parameters of the proposed models (microscopic and macroscopic) has been sought in this work. In particular, and as a first approximation, a neural network has been implemented that allows inferring the parameters of the macroscopic model having as input characteristic aspects of an immune response.

## Keywords

mathematical models, differential equations, T cells, pathogens, immune response, numerical simulations.



# Índice

|  |           |
|--|-----------|
| <b>1. Introducción</b>   | <b>1</b>  |
| 1.1. Objetivos . . . . .   | 2         |
| 1.2. Plan de trabajo . . . . .   | 2         |
| 1.3. Estructura del documento . . . . .  | 3         |
| <b>2. Estado de la Cuestión</b>  | <b>5</b>  |
| 2.1. Cuestiones básicas de inmunología . . . . .   | 5         |
| 2.1.1. El sistema inmune innato . . . . .  | 6         |
| 2.1.2. El sistema inmune adaptativo . . . . .  | 7         |
| 2.2. Cooperación entre dos ciencias: matemáticas y biología . . . . .  | 9         |
| 2.2.1. Dinámica de las células T. Decisión entre división o apoptosis . . . . .  | 11        |
| <b>3. Algoritmo de decisión de las células T durante la respuesta inmune. Modelo microscópico</b>                              | <b>13</b> |
| 3.1. Hipótesis biológicas . . . . .  | 14        |
| 3.1.1. La competición entre dos moléculas inhibidoras determina la decisión y la duración de la vida de una célula T . . . . . | 14        |
| 3.1.2. Los receptores de membrana regulan las dinámicas de Rb y Bcl-2 . . . . .  | 15        |
| 3.1.3. La primera división de las células T naïve tras su activación es asimétrica. . . . .                                    | 15        |
| 3.2. Modelo microscópico . . . . .   | 15        |
| 3.2.1. Aspectos técnicos del modelo . . . . .  | 17        |
| 3.3. Dinámica del patógeno durante la respuesta inmune . . . . .   | 17        |
| <b>4. Simulaciones del modelo microscópico</b>   | <b>19</b> |
| 4.1. Modelo simplificado . . . . .   | 19        |
| 4.2. Detalles de implementación y pseudocódigo . . . . .   | 20        |
| 4.3. Resultados y análisis . . . . .   | 23        |
| 4.3.1. Intolerancia al patógeno . . . . .  | 23        |
| 4.3.2. Tolerancia al patógeno . . . . .  | 24        |
| 4.3.3. Simulaciones con distintas poblaciones de células T . . . . .   | 25        |
| <b>5. Modelo macroscópico para la dinámica de población de las células T durante la respuesta inmune.</b>                      | <b>27</b> |
| 5.1. Inercia y elasticidad en las células T . . . . .  | 27        |

|   |           |
|---|-----------|
| 5.2. Simulaciones del modelo macroscópico . . . . .                                   | 29        |
| 5.2.1. Intolerancia al patógeno . . . . .   | 29        |
| 5.2.2. Tolerancia al patógeno . . . . .   | 30        |
| 5.2.3. Regiones de tolerancia e intolerancia . . . . .                                | 31        |
| <b>6. Correspondencia de parámetros entre los modelos microscópico y macroscópico</b> | <b>33</b> |
| 6.1. Conjunto de datos y entrenamiento de la red neuronal . . . . .                   | 34        |
| 6.1.1. Aspectos técnicos de la red . . . . .  | 35        |
| 6.2. Resultados obtenidos por la red neuronal . . . . .                               | 35        |
| 6.2.1. Ejemplo de ejecución de la red . . . . .                                       | 36        |
| <b>7. Conclusiones y Trabajo Futuro</b>   | <b>39</b> |
| <b>8. Introduction</b>  | <b>41</b> |
| 8.1. Objectives . . . . .   | 42        |
| 8.2. Work plan . . . . .  | 42        |
| 8.3. Document structure . . . . .   | 43        |
| <b>9. Conclusions and Future Work</b>   | <b>45</b> |
| <b>Bibliografía</b>   | <b>47</b> |
| <b>A. Código de las simulaciones</b>  | <b>49</b> |
| A.1. Código referente al Capítulo 4 . . . . .   | 49        |
| A.2. Código referente al Capítulo 5 . . . . .   | 54        |

# Índice de figuras

|  |    |
|--|----|
| 2.1. Fagocitosis. . . . .  | 6  |
| 2.2. Macrófago reconociendo una bacteria gracias a la acción <i>anticuerpo-antígeno</i> . . . . .  | 7  |
| 2.3. Proceso de activación de una célula T. . . . .  | 9  |
| 3.1. Representación del ciclo celular. . . . .   | 14 |
| 4.1. Simulaciones del modelo microscópico. Casos de intolerancia y tolerancia al patógeno . . . . .  | 24 |
| 4.2. Simulaciones del modelo microscópico. Poblaciones de células T con distinta afinidad al patógeno. . . . .   | 26 |
| 5.1. Simulación del modelo macroscópico. Caso de intolerancia al patógeno. Parámetros: $\alpha = 1,5$ , $\beta = 0,1$ , $k = 4$ , $\lambda = 0,5$ , $P_m = 0$ . . . . .              | 29 |
| 5.2. Simulaciones del modelo macroscópico. Casos de tolerancia al patógeno . . . . .   | 30 |
| 5.3. Simulación del modelo macroscópico adimensional. Variación de los parámetros $\alpha^*$ y $\beta^*$ para dar lugar a regiones de tolerancia e intolerancia al patógeno. . . . . | 31 |
| 6.1. Representación esquemática de una red neuronal. . . . .   | 35 |
| 6.2. Representación gráfica de los valores de <i>loss</i> y <i>accuracy</i> para cada <i>epoch</i> durante el entrenamiento de la red. . . . .                                       | 36 |
| 6.3. Ejemplo con simulaciones del modelo microscópico y macroscópico con los valores de los parámetros predichos por la red neuronal. Casos de intolerancia al patógeno. . . . .     | 37 |





# Índice de tablas

|   |    |
|---|----|
| 4.1. Tabla de variables y parámetros. . . . . | 21 |
|---|----|



# Introducción

El año 2018 fue proclamado Año Internacional de la Biología Matemática por dos sociedades científicas: la *European Mathematical Society* (EMS) y la *European Society for Mathematical and Theoretical Biology* (ESMTB). Con esta celebración se pretendía señalar la importancia de las aplicaciones de las matemáticas en la biología y en las ciencias de la vida y fomentar su interacción<sup>1</sup>. En la actualidad, las ciencias de la vida utilizan cada vez más aportaciones matemáticas, que van desde el uso de los sistemas dinámicos y la estadística, a los modelos de población y de propagación de enfermedades. En este contexto, los modelos cobran un papel relevante, puesto que son representaciones simplificadas de la estructura y del funcionamiento de un determinado sistema o proceso biológico, utilizando el lenguaje matemático para expresar las relaciones entre variables<sup>2</sup>. El uso adecuado de modelos permite avanzar más allá de lo que la mera intuición sugiere y nos suministra información útil que de otra manera sería difícil recabar, ya sea por el elevado coste económico de los experimentos, por el tiempo que lleva realizarlos o por la cantidad de datos a examinar, entre otras razones. Pero no solo los expertos se benefician del poder de simplificación de los modelos matemáticos. Durante la actual crisis sanitaria de la COVID-19, se han utilizado modelos matemáticos para predecir la propagación del virus y para informar a la sociedad del riesgo de esta pandemia<sup>3</sup>.

A lo largo de este documento nos centraremos en el campo de la inmunología. Es interesante observar que las células que componen el sistema inmune no están reguladas por un órgano coordinador (Arias y Herrero, 2016). Estas células se mueven libremente por el organismo y llevan una vida independiente. Sin embargo, son capaces de desplegar comportamientos colectivos, como es el caso de la respuesta ante agentes infecciosos. En esta función defensiva, las células T juegan un papel muy importante. Cuando se detecta una infección, la población de este tipo de células crece varios órdenes de magnitud en pocos días y, una vez desaparecido el agente infeccioso, los niveles de población vuelven a restaurarse mediante el suicidio (apoptosis) de gran parte de la población generada. El mecanismo de decisión entre división o apoptosis que toman las células T durante la respuesta inmune guarda aún muchos interrogantes. En los capítulos que siguen expondremos dos modelos matemáticos, basados en ecuaciones diferenciales, que intentan arrojar luz sobre este fenómeno. El primero de ellos, que puede verse en el Capítulo 3, aborda este asunto desde un punto de vista microscópico. Es decir, se propone un algoritmo de decisión

<sup>1</sup>[https://www.icmat.es/divulgacion/Material\\_Divulgacion/miradas\\_matematicas/06.pdf](https://www.icmat.es/divulgacion/Material_Divulgacion/miradas_matematicas/06.pdf)

<sup>2</sup><http://www.blogsanidadanimal.com/2018-el-ano-internacional-de-la-biologia-matematica/>

<sup>3</sup>Modelos matemáticos sobre la curva de crecimiento del COVID-19 en *The Washington Post*: <https://www.washingtonpost.com/graphics/2020/world/corona-simulator/>

implementado por cada célula. Por su parte, las ecuaciones del segundo modelo, expuesto en el Capítulo 5, describen el comportamiento dinámico de toda la población de células T, basado en dos características principales atribuidas a esa población: la elasticidad y la inercia. En ambos casos se realizan simulaciones numéricas de dichos modelos. Estas simulaciones representan distintas situaciones que pueden darse durante una infección. Entre ellas interesa distinguir entre la situación de intolerancia al patógeno, en cuyo caso las células inmunes consiguen controlar la infección y eliminar al agente infeccioso, o la situación de tolerancia al patógeno, en la que es este último quien acaba tomando el control del organismo. También se analiza qué ocurre cuando tenemos poblaciones de células T con distintas afinidades al patógeno. La relación entre las propiedades de ambos modelos constituye un tema interesante, que se aborda en el último capítulo (Capítulo 6). Como veremos, ambos dan lugar a resultados no solo compatibles sino complementarios.

## 1.1. Objetivos

Este Trabajo de Fin de Grado se centra en el estudio de la dinámica de población de las células T ante una infección aguda y, más concretamente, en el estudio de dos modelos matemáticos que pretenden dar respuesta a los mecanismos que rigen este comportamiento.

Para abordar este proyecto se determinaron los siguientes objetivos:

- Estudio básico del sistema inmune, enfocado a conocer el papel que juegan las células T durante una *respuesta inmune*.
- Estudio y comprensión de los modelos matemáticos que se detallan en este documento y de su importancia en el ámbito de la biología.
- Implementación del código necesario para simular distintos comportamientos de las células T basados en estos modelos y análisis de dichos comportamientos.
- Obtención de una primera aproximación para lograr establecer una correspondencia entre los parámetros de los dos modelos estudiados.

## 1.2. Plan de trabajo

Para la realización de este trabajo se establecieron distintos hitos a lo largo del curso académico. Los primeros meses estaban destinados a una revisión previa de los conceptos biológicos subyacentes. Los cuales engloban nociones básicas sobre el sistema inmune y un estudio más detallado del comportamiento de las células T. Esto constituye una parte fundamental del trabajo, pues los modelos no pueden ser comprendidos en su totalidad si no se miran desde el problema biológico al que intentan dar respuesta. Una vez se afanzara la base biológica se podía comenzar con el estudio de los modelos. El primero que se estudiaría sería el modelo microscópico expuesto en Arias et al. (2014). Se estableció la realización de distintas simulaciones del modelo, que complementarían la teoría vista. El segundo modelo, el modelo macroscópico (Arias et al., 2015), sería estudiado después, con el propósito de poder relacionarlo con el modelo anterior.

Una vez ambos modelos estuvieran revisados y se hubieran realizado las simulaciones correspondientes se abrió la posibilidad de intentar establecer una correspondencia entre los parámetros de ambos modelos mediante la implementación de una red neuronal. Esto último pondría fin al contenido de este Trabajo de Fin de Grado.

## 1.3. Estructura del documento

Este trabajo está dividido en cuatro partes bien diferenciadas, pero con la misma finalidad, el estudio de las células T y su dinámica de población durante una infección aguda.

1. En el Capítulo 2 se cubre el contexto del documento. En concreto, en la Sección 2.1 se tratan unas nociones básicas sobre inmunología, que permiten al lector continuar por los capítulos siguientes sin ningún impedimento terminológico, en cuanto a cuestiones biológicas se refiere. Esta sección pretende dar una visión general y muy básica del sistema inmune. Comienza con los mecanismos más simples, referentes al *sistema inmune innato* (Sección 2.1.1), hasta las más complejas, referentes al *sistema inmune adaptativo* (Sección 2.1.2). Más en detalle se exponen los aspectos de la respuesta inmune que involucran a las células T, como son su activación y actuación o la memoria inmune (Sección 2.1.2.1).

Por su parte, la Sección 2.2 aborda el papel de los modelos matemáticos en el campo de la biología. Concretamente en la Sección 2.2.1, nos centramos en el caso de nuestro estudio, los distintos modelos matemáticos formulados para la dinámica de las células T durante una infección aguda.

2. En el Capítulo 3 se expone el marco teórico del modelo microscópico propuesto para el problema de decisión entre división y apoptosis de las células T. En la Sección 3.1 se detallan las hipótesis biológicas sobre las que se sustenta el modelo, que constituyen hechos contrastados y observados en el campo de la biología. El modelo en sí puede verse en la Sección 3.2, donde se detalla la notación que seguirá el resto del documento y las ecuaciones diferenciales de primer orden que dan lugar al algoritmo. La última sección de este capítulo, la Sección 3.3, introduce una ecuación diferencial para la dinámica de población del patógeno y su relación con la cantidad de células T disponibles. La ecuación establece la interacción entre ambas poblaciones.

En el Capítulo 4 se presentan las simulaciones correspondientes a un caso simplificado del modelo anterior (Sección 4.1) y se explican los detalles básicos de la implementación del mismo (Sección 4.2). Los resultados de las simulaciones se exponen en la Sección 4.3. Estas simulaciones corresponden a casos de intolerancia y tolerancia al patógeno (Secciones 4.3.1 y 4.3.2, respectivamente), así como el caso de la respuesta inmune con poblaciones de células T con distintas afinidades al patógeno (Sección 4.3.3).

3. El modelo macroscópico se estudia en el Capítulo 5. Las ecuaciones diferenciales de segundo grado de este modelo rigen la dinámica de población de las células T y el patógeno de manera colectiva, a diferencia del modelo microscópico, cuyo algoritmo estaba definido para cada una de las células. Este modelo está basado en dos características del comportamiento de la población de células T durante una respuesta inmune: la elasticidad y la inercia (Sección 5.1).

Además de proponerse un modelo teórico, también se realizan las simulaciones numéricas correspondientes al modelo en la Sección 5.2. Estas recogen los casos de intolerancia y tolerancia al patógeno (Secciones 5.2.1 y 5.2.2, respectivamente) y, para el modelo macroscópico adimensional, se estudia la relevancia del valor de sus dos parámetros en las regiones de tolerancia e intolerancia (Sección 5.2.3).

4. A continuación, una vez estudiados los modelos propuestos en los Capítulos 3 y 5, y tras la comparación de sus resultados, se busca una correspondencia de parámetros

entre ambos modelos en el Capítulo 6. Para ello se implementa una red neuronal capaz de realizar “la función inversa” al código referente a las simulaciones del modelo macroscópico. Es decir, dados los resultados de una simulación, predecir el valor de los parámetros necesarios para obtener ese mismo resultado. La construcción del conjunto de datos y la implementación de la red puede verse en la Sección 6.1. Los resultados obtenidos y un ejemplo de ejecución, usando como entrada los resultados de una simulación del modelo microscópico, pueden verse en la Sección 6.2.

Por último, el Capítulo 7 ofrece una breve conclusión sobre el trabajo realizado. A fin de complementar el proyecto, se ha incluido el código principal de las simulaciones de los modelos (tanto las del Capítulo 4 como las del 5) en el Apéndice A.

# Capítulo 2

## Estado de la Cuestión

En este capítulo revisaremos los aspectos necesarios para la comprensión de los modelos que se exponen en los capítulos que siguen. La Sección 2.1 brinda unas nociones básicas sobre inmunología, en las que se trata brevemente el estudio de los mecanismos y agentes del sistema inmune humano necesarios para la respuesta ante una infección, destacando el papel de las células T. Esta sección constituye una parte fundamental del trabajo, pues los modelos que se presentan a continuación deben ser entendidos a través del problema inmunológico que intentan explicar. Por su parte, la Sección 2.2 habla sobre los modelos matemáticos en el campo de la biología y, más concretamente, sobre algunos de los que han abordado el problema de decisión entre división o apoptosis de las células T durante una infección aguda.

### 2.1. Cuestiones básicas de inmunología

Antes de comenzar es conveniente introducir una serie de definiciones y explicaciones básicas referentes al sistema inmune humano. De esta manera, los conceptos y modelos que se expondrán más adelante serán entendidos en su contexto y sin ningún impedimento terminológico.

En la Sección 1 de Introducción ya decíamos que en el sistema inmune es posible observar comportamientos colectivos que son consecuencia de las decisiones individuales que toman sus células. Este sistema está compuesto por diversos agentes que trabajan de forma coordinada para dar una respuesta eficaz y proporcional al ataque recibido. Este último adjetivo es muy importante: necesitamos que la actuación de nuestro sistema inmune no sea insuficiente, lo que podría acarrear alguna inmunodeficiencia, ni tampoco excesiva, que es lo que ocurre, por ejemplo, con las alergias: el sistema inmune reacciona de manera exagerada a ciertos *antígenos* que son, en la mayoría de casos, inofensivos. Otro de los requisitos que debe tener un buen sistema inmune es la capacidad para discriminar a quién hay que atacar y a quién no, evitando que las células del propio organismo sean blanco de su acción. Esto último es lo que sucede en el caso de las enfermedades autoinmunes, que pueden llegar a ser trastornos muy graves.

Describiremos brevemente a continuación los mecanismos de los que dispone el sistema inmune y cómo los utiliza. Haremos un recorrido desde lo más básico, comenzando por el *sistema inmune innato*, hasta conceptos más avanzados referentes al *sistema inmune adaptativo*. Dedicaremos buena parte de esta sección a entender qué son las células T y cuál es su papel en el desarrollo de una respuesta ante una infección aguda. Como




Figura 2.1: Fagocitosis.

veremos, este tipo de células inmunes juega un papel primordial y, además, serán las grandes protagonistas de este Trabajo de Fin de Grado (Arias et al., 2014).

### 2.1.1. El sistema inmune innato

Comencemos por lo más simple: las barreras físicas. La piel y la mucosa de nuestro sistema respiratorio, digestivo y reproductivo intentan que virus, bacterias, hongos o parásitos no entren en nuestro organismo. Es la primera defensa que tenemos y es bastante efectiva en muchos casos, pero ¿qué pasa si estos agentes logran atravesar esta barrera?

Aquí entra en juego lo que se denomina *sistema inmune innato* que, desde el punto de vista evolutivo, es el más antiguo de los sistemas inmunes de los seres vivos. De hecho, muchos mecanismos de este sistema inmune innato aparecieron hace más de 500 millones de años (Sompayrac, 2016). A pesar de que dispone de mecanismos mucho más sencillos que el *adaptativo*, el papel que tiene es fundamental, pues permite dar una primera respuesta rápida ante una infección.

Entre las armas de las que dispone encontramos proteínas, fagocitos y células NK (*Natural Killer*), que son un tipo de linfocito producido en la médula ósea y que se distribuye por la piel, el intestino, el hígado, los pulmones y el útero, entre otros tejidos (Taborda et al., 2014). Pero nos centraremos en uno de sus componentes más relevantes: los *macrófagos*. Su nombre compuesto por dos palabras griegas: *macro*, que significa grande y *fago*, que significa comer, lo dice todo. En efecto, los *macrófagos* son células que se comen invasores mediante un proceso llamado *fagocitosis*, que ilustra la Figura 2.1. Durante la batalla con las bacterias, los *macrófagos* producen y secretan unas proteínas llamadas citoquinas, que facilitan la comunicación entre células del sistema inmune y que cobrarán un papel muy relevante en los capítulos que siguen. Podríamos decir que los *macrófagos* además de atacar a los invasores, pueden jugar el papel de centinelas, que cuando ven al enemigo mandan señales (citoquinas) para reclutar a más defensores. A continuación, veremos otros tipos de células, en este caso referentes al *sistema inmune adaptativo*.





Figura 2.2: Macrófago reconociendo una bacteria gracias a la acción *anticuerpo-antígeno*.

### 2.1.2. El sistema inmune adaptativo

Cuando el sistema innato no es suficiente para detener el ataque de un patógeno, lo que ocurre por ejemplo si un virus logra evadir a los macrófagos de guardia o penetrar en células humanas para reproducirse en ellas, entra en acción el llamado *sistema adaptativo*, que está presente en humanos y vertebrados, pero no en la totalidad de los seres vivos.

Para explicar su funcionamiento necesitamos hacer uso de los conceptos de *antígeno* y *anticuerpo*. Los *anticuerpos* son proteínas específicas que el cuerpo humano es capaz de producir y que pueden adherirse a otras sustancias, externas o internas, llamadas *antígenos*. La misión principal de los *anticuerpos* es identificar a los *antígenos* generados por un agente patógeno, marcándolos así para su eliminación. Las células encargadas de la producción de *anticuerpos* son las células B. Estas son un tipo de linfocito producido en la médula que, gracias a sus receptores de membrana, son capaces de identificar determinados complejos anticuerpo/antígeno para poder eliminar así a estos últimos. Cuando las células B nacen no están especializadas en la fabricación de un *anticuerpo* concreto. Una vez que maduran, su ADN se recombina especializando así a la célula. Una vez que la célula B se encuentra con su *antígeno* desencadenante, ésta produce muchas células grandes conocidas como *células plasmáticas*. Cada *célula plasmática* es esencialmente una fábrica para producir *anticuerpos*.

Es decir, gracias a la presencia de *anticuerpos*, otras células, como los ya conocidos *macrófagos*, son capaces de identificar a los elementos que hay que destruir cuando aún se encuentran en el medio extracelular como muestra la Figura 2.2. Pero... ¿qué ocurre cuando un virus ya ha entrado en una célula de nuestro cuerpo? Los *anticuerpos* no pueden alcanzarlo y el virus puede dedicarse a replicarse cuanto quiera. En este momento llega el turno de las protagonistas de este trabajo, las células T.

#### 2.1.2.1. Las células T

Al igual que las células B, las células T se producen en la médula y ambas son muy similares en cuanto a su apariencia, de hecho, con un microscopio ordinario, un inmunólogo no sería capaz de diferenciarlas (Sompayrac, 2016). La superficie de las células T también consta de unas moléculas que permiten la interacción con los *antígenos* llamados receptores (TCR, *T Cell Receptors*). Estos receptores permiten a estas células obtener información de su entorno y tomar decisiones en base a esa información. Por ejemplo, cuando los receptores de una célula T enlazan con un *antígeno* compatible, las células proliferan para dar lugar a otras con la misma especificidad, es decir, que enlacen con el mismo *antígeno*. Esta decisión de reproducción, que discutiremos con más detalle en los capítulos que siguen, es específica y lenta, tarda alrededor de una semana en completarse (Sompayrac, 2016), lo que contrasta

con la respuesta rápida que ofrece el *sistema inmune innato*.

Hemos visto algunas de las similitudes que tienen las células B y T. Veamos algunas de sus diferencias: las células T maduran en el timo, de ahí la T de su nombre, mientras que las B maduran en la médula ósea. Además, las células B producen *anticuerpos* que pueden reconocer cualquier molécula orgánica. Las células T, por su parte, están especializadas en el reconocimiento de un *antígeno* específico y sus receptores permanecen siempre adheridos a la membrana celular y no pueden ser expulsados en forma de *anticuerpo* como en el caso de las células B. Pero, quizá, la diferencia más importante sea que las células T no pueden reconocer al *antígeno* “por sí mismas”, necesitan que otra célula se lo presente (Sompayrac, 2016). Las células que se encargan de ello se conocen como *células presentadoras de antígeno*<sup>1</sup>. Las proteínas del microorganismo causante de la infección, una vez fagocitadas, son fragmentadas (formando los conocidos *antígenos*) y transportadas hasta la superficie celular, donde quedan unidas a una estructura llamada *complejo mayor de histocompatibilidad* (MHC) que se encuentra en la membrana de las *células presentadoras de antígeno*. Gracias a su TCR las células T pueden reconocer aquellas células que han sido infectadas, puesto que el TCR y el MHC-péptido<sup>2</sup> encajan, la Figura 2.3 ilustra este proceso. Esta unión, si es perfecta, dura varias horas y se conoce como *sinapsis inmunológica* (Fernández Arias, 2012).

Hay distintos tipos de células T atendiendo al papel que desempeñan, los tres más importantes son:

- *Killer o Cytotoxic T-Cells*: su misión es la de reconocer las células que han sido infectadas y, tras este proceso de reconocimiento, inducirles al suicidio. De esta manera muere el virus, pero también la célula que había sido infectada por él. Constituyen una de las armas más potentes del sistema inmune.
- *Helper T-Cells*: se encargan de regular la respuesta inmune. Una de sus tareas principales es secretar citoquinas para controlar que la respuesta inmune sea proporcional y las células T no reaccionen de manera descontrolada.
- *Regulatory T-Cells*: estas mantienen la tolerancia a *antígenos* propios, previniendo la aparición de enfermedades autoinmunes.

Cuando las células T salen del timo se encuentran desactivadas, en un estado *naïve*, y se dedican a circular por los órganos linfoides secundarios, cuyos máximos representantes son los nodos linfáticos. Allí pueden encontrarse con *células presentadoras de antígeno* provenientes del foco de una infección. Si las células T reconocen al *antígeno* como extraño por medio de la *sinapsis inmune*, se activan, convirtiéndose así en células efectoras, capaces de secretar citoquinas o de ir a la zona afectada a combatir la infección activamente. Una vez que las células han sido activadas, estas comienzan a proliferar masivamente, incrementando la población de células T activadas hasta en un factor de  $10^6$  veces. En pocos días, las células pueden pasar por unos 15-20 ciclos de reproducción (Arias et al., 2014). Este proceso se conoce como *expansión clonal*. Una vez que las células *helper* han sido activadas pueden quedarse en los ganglios linfáticos, activando a otras células inmunitarias, o migrar al tejido infectado para secretar citoquinas y propiciar un ambiente adecuado para controlar la infección. Por su parte, las células *killer* abandonan los ganglios linfáticos para identificar aquellas células infectadas en el organismo. Cuando el patógeno ha sido vencido, la mayoría de células T mueren, restaurando así los niveles de población iniciales (en caso

<sup>1</sup>Son macrófagos, células dendríticas, células B, entre otras.

<sup>2</sup>Estructura formada por el MHC y el *antígeno*.



Figura 2.3: Proceso de activación de una célula T.

contrario se acumularían millones de células que no son necesarias para el organismo) (Fernández Arias, 2012). Este proceso se conoce como *contracción clonal*. Sin embargo, es de gran utilidad conservar alguna de estas células experimentadas para poder reaccionar con rapidez en caso de que el mismo invasor vuelva a aparecer. Lo que hace nuestro sistema inmune es mantener un pequeño porcentaje de la población (5 – 10%) como células de memoria (Arias et al., 2014). Se llaman así porque guardan información del *antígeno* contra el que combatieron. En caso de reaparición del patógeno, estas células se activan más rápidamente y nuestro cuerpo puede así generar antes una respuesta inmune.

A lo largo de este trabajo nos centraremos en el proceso de decisión entre división o suicidio celular de una célula T durante la respuesta inmune. En la sección y los capítulos que siguen veremos cómo se ha abordado este problema desde el punto de vista matemático y las conclusiones que su estudio ha permitido obtener.

## 2.2. Cooperación entre dos ciencias: matemáticas y biología

En esta sección trataremos brevemente la interacción entre dos ciencias muy distintas: las matemáticas y la biología, y daremos algunos ejemplos de colaboraciones y modelos matemáticos creados para reproducir e investigar distintos procesos biológicos. Nos centraremos en aquellos referidos a las células T, sobre todo al caso que nos ocupa: la dinámica de población de las mismas durante la respuesta inmune.

Después de haber seguido un desarrollo independiente durante siglos, las matemáticas y la biología han comenzado a interactuar activamente durante los últimos años. De hecho, los modelos matemáticos pueden llegar a ser una potente herramienta en el área de la biología. Como se puede leer en Gunawardena (2014), un modelo matemático es una máquina lógica que convierte hipótesis en conclusiones. Si el modelo es correcto y las hipótesis son ciertas entonces debemos, por lógica, creer sus conclusiones. Esta garantía lógica permite al matemático que desarrolla el modelo navegar con confianza lejos de las hipótesis y, probablemente, más lejos del lugar al que la mera intuición permite llegar.

Así pues, los modelos matemáticos son herramientas en las que un biólogo se puede

apoyar, pero estos modelos deben tener ciertas características para poder considerarse de utilidad en Biología. A continuación, se presentan las guías que sugiere Gunawardena (2014) para elaborar un buen modelo matemático:

1. *Formula una pregunta.* En ocasiones los modelos matemáticos no son diseñados para el avance del conocimiento de la biología, solo responden a investigaciones matemáticas que se basan, aparentemente, en problemas biológicos. Como ya se ha comentado en alguna ocasión, los modelos deben centrarse en aportar información que el biólogo desconocía. Intentar responder con un modelo a una pregunta puede ser clave a la hora de desarrollarlo con criterio, para que pueda ser juzgado por profesionales fuera del ámbito matemático.
2. *Hazlo simple.* Incluir todos los procesos bioquímicos puede tranquilizar a los biólogos, pero no hará que el modelo sea mejor. De hecho, se convertirá en un modelo repleto de parámetros, poco flexible, difícil de estudiar y simular. Es mejor tener hipótesis simples y claras, intentando buscar una abstracción adecuada del problema.
3. *No es suficiente con que el modelo reproduzca hechos observados.* Si el modelo no puede ser comprobado ni refutado, entonces no está diciendo nada interesante. Ajustar los parámetros del modelo para que reproduzcan una observación no garantiza nada: un mismo fenómeno se puede representar mediante modelos distintos con parámetros diferentes

Podemos distinguir dos tipos de estrategia en cuanto a los modelos se refiere: Modelado hacia adelante (*forward modeling*) o inverso (*reverse modeling*). El modelado inverso empieza con los datos experimentales, construye correlaciones entre ellos y les da estructura con un modelo matemático. Por su parte, el modelado hacia adelante empieza desde lo conocido, o sospechado, expresado en la forma de un modelo, a partir del cual se hacen predicciones.

El modelado inverso se ha utilizado con el fin de analizar grandes volúmenes de datos genómicos y postgenómicos y, a veces, se equipara erróneamente con la biología de sistemas. Ocasionalmente ha sugerido nuevas ideas conceptuales, pero se ha utilizado con mayor frecuencia para sugerir nuevos componentes o interacciones moleculares, que luego han sido confirmados por enfoques biológicos convencionales. Los modelos en sí mismos han tenido menos importancia para comprender el comportamiento del sistema que como contexto matemático en el que la inferencia estadística se vuelve factible. En contraste, las mayores aportaciones a nuestra comprensión del comportamiento de problemas biológicos, como la homeostasis o la retroalimentación, han surgido del modelado hacia adelante. Puesto que los modelos actuales (cimentados en ecuaciones diferenciales o teoría de procesos estocásticos, por ejemplo) derivan, normalmente, de fenómenos y conocimiento conocidos. El primer beneficio que se obtiene de esto es que fuerzan al modelo a establecer unas hipótesis claras (Castro et al., 2016). Esto no implica que el modelado inverso no sea interesante. Hay muchas situaciones, especialmente cuando se tratan datos clínicos, donde la estructura de los datos se desconoce o es muy compleja, y las estrategias del modelado inverso cobran sentido (Gunawardena, 2014).

A continuación, y teniendo presentes las observaciones anteriores, describiremos el punto de vista seguido en los artículos en los que se basa este trabajo.

### 2.2.1. Dinámica de las células T. Decisión entre división o apoptosis

Recordemos brevemente el marco conceptual en el que nos movemos. En 2.1.2.1 decíamos que cuando las células T se activan en presencia de un *antígeno* estas comienzan a reproducirse rápidamente para combatir la infección y, una vez superada, muchas de ellas se suicidan restaurando los valores de población iniciales. Es lo que denominábamos respectivamente como *expansión clonal* y *contracción clonal*. Más aún, los experimentos realizados ponen de manifiesto que la presencia del *antígeno* no es suficiente para desencadenar la decisión de división o apoptosis, ya que las células T activadas continúan reproduciéndose incluso cuando el estímulo (*antígeno*) está ausente y algunas se suicidan aun cuando la infección persiste (Arias et al., 2014). Estos son hechos observados; lo que se desconoce es el mecanismo de decisión por el cual una célula decide dividirse o morir. Varios modelos matemáticos, desarrollados bajo diferentes hipótesis, han sido propuestos para abordar este problema. Por una parte, se ha sugerido que el proceso de activación de las células T en estado *naïve* desencadena un programa que solo depende de la estimulación por *antígeno* inicial. Así las cosas, una célula T efectora (y por tanto, ya activada) comienza una serie de divisiones, desde un mínimo entre 7 y 10 y un máximo variable (relacionado con la estimulación por *antígeno* que recibió cada célula de manera individual durante su activación) (Hawkins et al., 2007). Después de estas divisiones, la célula se suicida. Bajo esta suposición, la cantidad de *antígeno* que percibe una célula T en estado *naïve* durante su activación determina las divisiones de todas sus células hijas. Para precisar más este modelo, se propuso que este programa pudiera estar regulado también mediante citoquinas y no solo por la presencia de *antígeno*, aunque los detalles concretos de esta regulación no son conocidos (Arias et al., 2014). Por otro lado, se han propuesto alternativas a este modelo basadas en procesos estocásticos. En este caso la decisión entre división o apoptosis de una célula T vendría determinada por la competición de dos relojes estocásticos (Duffy y Hodgkin, 2012). Como ocurría en el caso anterior, los procesos celulares y moleculares específicos para dilucidar este algoritmo de decisión aún están en el aire.

En esta memoria, presentamos otro modelo, expuesto en Arias et al. (2014), cuyas hipótesis biológicas, ecuaciones y simulaciones se desarrollan durante los dos capítulos siguientes. Es un modelo que basa la decisión de cada célula T en la concentración de *antígeno* y de dos proteínas inhibitoras, Retinoblastoma (Rb) y linfoma de célula B-2 (Bcl-2), que la célula encuentra en el medio extracelular que la rodea. Este algoritmo determinista distingue este modelo de los mencionados anteriormente y permite que cada célula decida, en función de la información que obtiene de su alrededor, la duración de su vida, si debe dividirse o no y el momento en el que debe hacerlo. Como veremos, esta anarquía a nivel individual se traduce en una propiedad emergente a nivel colectivo que concuerda con los hechos biológicos observados.




## Algoritmo de decisión de las células T durante la respuesta inmune. Modelo microscópico

El modelo matemático que se presenta a continuación pretende proporcionar una explicación al proceso que rige la dinámica de población de las células T durante la respuesta del sistema inmune ante una infección aguda (problema expuesto en la Sección 2.2.1). Denominamos microscópico a este modelo puesto que propone un algoritmo de decisión, entre división o apoptosis, para cada célula T.

Para la formulación del modelo se ha seguido la siguiente estrategia: a partir de unas hipótesis, que corresponden a hechos experimentales conocidos (ver Sección 3.1), se formulan ecuaciones diferenciales muy simples que, de hecho, pueden resolverse de manera explícita. Esta simplicidad es una de las principales características del modelo. Entre otras cosas, se consigue así reducir el número de parámetros al mínimo, con lo que las simulaciones del mismo son más fáciles de analizar e interpretar. Las ecuaciones propuestas en la Sección 3.2 modelizan tanto la dinámica de las células T efectoras, sin olvidar las de memoria, como la dinámica del patógeno (Sección 3.3). Nuestro modelo difiere sustancialmente de muchos otros propuestos hasta la fecha. Por ejemplo, prescindimos de la hipótesis de que las células se dividen un número fijo de veces después de ser activadas (Hawkins et al., 2007) o de que la decisión entre dividirse o suicidarse sea en cada célula el resultado de una competencia entre relojes estocásticos internos de vida o suicidio celular (Duffy y Hodgkin, 2012). En su lugar, asumiremos en nuestro modelo que estas decisiones (división o apoptosis) vienen determinadas por la competición de dos moléculas inhibidoras: Retinoblastoma (Rb), que previene la expresión de genes necesarios para que la célula pueda continuar el ciclo celular y dividirse, y linfoma de célula B-2 (Bcl-2), que bloqueará la muerte celular. La presencia en las células de tales inhibidores es bien conocida (Fernández Arias, 2012). También tendremos en cuenta que las células T se comunican con el exterior gracias a sus receptores TCR (ver 2.1.2.1) y, por tanto, sus decisiones se ven afectadas por la cantidad de receptores que presenten (cuantos más receptores, más estímulos serán capaces de percibir), así como por la presencia externa de ligandos capaces de interactuar con dichos receptores.

Los fenómenos de *expansión* y *contracción clonal* pueden ser considerados desde una perspectiva global como la consecuencia de muchas decisiones individuales. Cada célula T basa sus decisiones únicamente en la información que recoge de su entorno inmediato. Por ello, presentamos en primer lugar un modelo microscópico, en el que se modeliza la decisión



### 3.1. Hipótesis biológicas

### 3.1.1. La competición entre dos moléculas inhibidoras determina la decisión y la duración de la vida de una célula T

En nuestro modelo consideramos que la célula pasa el *punto de restricción*<sup>2</sup> (ver Figura 3.1) si la concentración de Bcl-2 o de Rb de su entorno cae por debajo de cierto límite. Esto es, cuando el número de moléculas de Rb activas disminuye hasta un valor crítico, la célula abandona  $G_1$  para iniciar la división celular y, cuando la cantidad de moléculas

<sup>2</sup>El punto de restricción es el punto entre las fases  $G_1$  y  $S$ , donde pasamos del crecimiento celular a la división (o apoptosis).



de Bcl-2 alcanza un umbral, la célula abandona  $G_1$  para poner en marcha los mecanismos que llevan a la muerte celular. La variación temporal de las concentraciones de Rb y Bcl-2 permite explicar la variabilidad observada en la duración de la fase  $G_1$  de las células y, consecuentemente, en la duración de sus vidas.

### 3.1.2. Los receptores de membrana regulan las dinámicas de Rb y Bcl-2

La fluctuación en la cantidad de Rb y Bcl-2 depende de unas proteínas llamadas citoquinas, que ya fueron mencionadas en la Sección 2.1. Estas pueden inducir tanto la fosforilación de Rb, en cuyo caso se denominan *citoquinas de proliferación*, como tener un efecto positivo o negativo en cuanto a la cantidad de Bcl-2 se refiere, en ese caso nos referiremos a ellas como citoquinas de supervivencia o muerte, respectivamente.

La acción que las citoquinas llevan a cabo se produce gracias sus interacciones con receptores de membrana específicos. De esta manera, el efecto que percibe una célula T depende, no solo de la cantidad de citoquinas del ambiente, sino también del número de receptores de membrana de la célula. Si, por ejemplo, tenemos una concentración muy alta de cierta citoquina, podríamos asumir que el efecto que esta va a tener en una célula T vendrá determinado por la cantidad de receptores de membrana específicos para ella que posea la célula en cuestión. También sabemos que el número de receptores de membrana de una célula varía a lo largo de su vida, haciendo así que células adyacentes que compartan un entorno similar (en el que la concentración de citoquinas sea la misma, por ejemplo) presenten comportamientos distintos si expresan diferentes receptores de membrana.

### 3.1.3. La primera división de las células T naïve tras su activación es asimétrica.

Postulamos que tanto los fenotipos de las células T efectoras como los de las células T con memoria se determinan durante la *sinapsis inmune*. Esto es, una célula T en estado *naïve* puede diferenciarse en una célula T efectora o en una célula T de memoria. Por su parte, tras esta primera división, las células T efectoras y de memoria, se dividen de manera simétrica, es decir, las células hijas heredarán el tipo de la madre, y ambos tipos se comportan de forma similar durante la respuesta inmune.

## 3.2. Modelo microscópico

Basándonos en las hipótesis anteriormente formuladas proponemos a continuación una serie de ecuaciones, con variables continuas y discretas, que darán forma al algoritmo de decisión de nuestro estudio. Como ya habíamos avanzado, se trata de un modelo simple, en el que los sistemas de ecuaciones diferenciales de primer orden propuestos tienen solución explícita. Sin embargo, es esta simplicidad la que hace de él un modelo tan potente, pues, como veremos en el capítulo siguiente, obtendremos resultados que no solo se ajustan a los hechos observados, sino que ponen de manifiesto comportamientos poblacionales difícilmente observables en el laboratorio.

Antes de expresar en términos matemáticos las condiciones del modelo, estableceremos la notación a seguir y haremos algunas aclaraciones previas:

- Denotaremos por  $c(t)$  y  $a(t)$  la cantidad de Rb y Bcl-2 activa en tiempo  $t$ , respectivamente.

- Establecemos, sin pérdida de generalidad, que los límites que determinan la decisión entre división o apoptosis (ver hipótesis 3.1.1) estarán en  $c(t) = 0$  y  $a(t) = 0$ , respectivamente. De acuerdo a esta hipótesis definimos:
  - *Decisión*: Fase que parte desde el nacimiento de la célula hasta que una de las moléculas inhibidoras alcanza el umbral establecido.
  - *Ciclo*: Fase que se extiende desde la *punto de restricción* hasta la división celular.
  - *Apoptosis*: Tiempo de vida de la célula que comprende desde la desactivación de Bcl-2 y la finalización del programa de muerte celular ACAD (*Activated T Cell Autonomous Death*).
  - *División*: Estado final después de que la célula haya entrado en la fase de ciclo.
  - *Muerte*: Estado final después de haberse completado la fase de apoptosis.
- $R_i$  será el receptor de la  $i$ -ésima citoquina y  $r_i(t)$  será la cantidad de ese receptor en tiempo  $t$ .
- $r_T$  es el número de señales TCR/antígeno percibidas por la célula T correspondiente.
- Los parámetros  $\mu_{Tc}$  y  $\mu_{Ta}$  denotan la tasa de cambio de las moléculas inhibidoras por cada señal del TCR. A su vez los parámetros  $\mu_{ic}$  y  $\mu_{ia}$  representan las tasas de cambio de las moléculas inhibidoras por cada señal  $R_i$ .
- $\lambda_{Tj}$  es la tasa de cambio del receptor  $R_j$  por cada señal del TCR. Por su parte  $\lambda_{ij}$  es la tasa de cambio del receptor  $R_j$  por cada señal  $R_i$ .
- $k$  es el número de receptores de membrana.

Así las cosas, ya estamos en condiciones de presentar las ecuaciones del modelo. Como ya hemos visto en la Sección 3.1, la dinámica de los inhibidores está controlada por las señales que recibe la célula de sus receptores de membrana durante la fase de decisión. Además, este número de señales depende del número de receptores de la célula. De acuerdo con estas observaciones, proponemos las siguientes ecuaciones:

$$\begin{cases} \dot{c}(t) = \mu_{Tc}r_T(t) + \sum_{j=1}^k \mu_{jc}r_j(t) \\ \dot{a}(t) = \mu_{Ta}r_T(t) + \sum_{j=1}^k \mu_{ja}r_j(t) \end{cases} \quad (3.1)$$

Con el Sistema 3.1 ponemos de manifiesto que las concentraciones de Rb y Bcl-2, representadas por  $c(t)$  y  $a(t)$ , respectivamente, dependen del número de señales TCR/antígeno ( $r_T$ ) y, del número de receptores de membrana que posea la célula en cuestión ( $r_i$ ).

Asumimos que los receptores de membrana involucrados en el algoritmo de decisión de las células T son independientes y tienen efectos aditivos. Según la Hipótesis 3.1.2, asumimos que las células son capaces de “contar” el número de señales que llegan. De acuerdo con estas relaciones lineales obtenemos un modelo robusto, puesto que configuraciones similares de receptores de membrana provocarán decisiones celulares similares. Teniendo en cuenta lo anterior proponemos la siguiente ecuación para los receptores de membrana:

$$\dot{r}_i(t) = \lambda_{Ti}r_T(t) + \sum_{j=1}^k \lambda_{ji}r_j(t) \quad \text{para } i = 1, \dots, k \quad (3.2)$$

### 3.2.1. Aspectos técnicos del modelo

En esta breve sección presentamos algunos aspectos técnicos del algoritmo propuesto, entre los que se incluyen las condiciones que marcaran en cambio de fase de una célula T, es decir, la condición que propiciará el paso de la fase de *decisión* a *ciclo*, por ejemplo, o los parámetros asignados a las células hijas al nacer .

- Las condiciones  $a(t) \geq 0$ ,  $c(t) \geq 0$  y  $r_i(t) \geq 0$ , para  $i = 1, \dots, k$  definen el dominio de las Ecuaciones 3.1 y 3.2 durante la fase de decisión.
- Cualquier receptor con valor negativo  $r_i(t) < 0$  es *reseteado* a 0 sin cambiar la fase de decisión en la que está la célula.
- Por su parte, las condiciones  $a(t) = 0$ ,  $c(t) = 0$  desencadenan el inicio de la fase de apoptosis y ciclo, respectivamente. Estas fases son excluyentes y no se pueden revertir mediante estimulación por citoquinas. Además, tienen longitud constante que denotaremos por  $t_{apo}$  y  $t_{cycle}$ , respectivamente.
- Si la célula progresa en la fase de ciclo los valores de  $a(t)$  y  $c(t)$  deben ser reiniciados para que las células hijas puedan comenzar la fase de decisión otra vez.
- Una vez que la célula termina la fase de apoptosis es retirada de la población.
- Los parámetros  $\lambda_{ji}$ ,  $\mu_{ic}$ ,  $\mu_{ia}$ ,  $\mu_{Tc}$ ,  $\mu_{Ta}$ ,  $c(0)$  y  $a(0)$  se consideran parámetros estructurales, es decir, se refieren a procesos biológicos que permanecen constantes durante la simulación. Por su parte, los parámetros referentes a la composición de receptores de membrana para una célula concreta  $r_{i0}$  dependen de la historia de encuentros con el antígeno que ha tenido su madre y diferirán entre las células hijas cuando esta se divida (veremos cómo en la sección siguiente).

## 3.3. Dinámica del patógeno durante la respuesta inmune

En esta sección se propone una ecuación que modela la interacción del patógeno con las células T. Debemos recordar que la dinámica de un patógeno depende en gran cantidad de las características de este. Sin embargo, en esta sección daremos unas ecuaciones muy generales a fin de que puedan ser aplicadas a la mayor cantidad posible de situaciones. En concreto, la dinámica del patógeno viene dada por:

$$\dot{y}(t) = \alpha y(t) - \beta n(t)y(t) \quad (3.3)$$

Donde  $y(t)$  y  $n(t)$  denotan el número de células del patógeno y el número de células T, respectivamente. Los parámetros  $\alpha$  y  $\beta$  son positivos y dependen del antígeno:  $\alpha$  representa la tasa de proliferación del patógeno, mientras que  $\beta$  corresponde a la tasa de eliminación del mismo a causa de las células T.

De acuerdo con este modelo, la Ecuación 3.3 sugiere que el patógeno aumenta su población hasta que el número de células T alcanza cierto valor crítico, obtenido al anular el segundo miembro de dicha ecuación. En ese momento  $\dot{y}(t)$  se hace negativa y, en consecuencia,  $y(t)$  comienza a decrecer. A su vez, en ausencia de células T, el patógeno crece de manera exponencial. Asumiremos que las señales captadas por el TCR de una célula T son proporcionales al número de encuentros que tenga con el antígeno. Si llamamos al número de señales TCR de una célula  $x$  en tiempo  $t$ ,  $r_T^x(t)$ , tenemos:

$$r_T^x(t) = \gamma \rho_n^x y(t) \quad (3.4)$$

Donde  $\gamma$  es un parámetro que depende del antígeno y denota la probabilidad de que haya una activación del TCR debido a un encuentro con el antígeno. Por otro lado,  $\rho_n^x$  representa la cantidad de antígeno que está disponible para una célula T,  $x$ , en porcentaje. Luego:

$$\sum_{x=1}^n \rho_n^x \leq 1 \quad (3.5)$$

Según la Hipótesis 3.1.3, las células T que ya se han diferenciado se dividen de manera simétrica y reparten sus receptores de membrana entre sus dos células hijas. De esta manera, la experiencia con el antígeno propia de cada célula puede ser transmitida a la siguiente generación. Las ecuaciones que determinan el número de receptores de membrana iniciales para las células hijas son:

$$\begin{cases} r_{i0}^1 = \delta_i^x r_i^x \\ r_{i0}^2 = (1 - \delta_i^x) r_i^x \end{cases} \quad (3.6)$$

Donde  $\delta_i^x$  representa el ratio de receptores de membrana de tipo  $R_i$  entre las células hijas,  $r_i^x$  denota el número de receptores  $R_i$  en la célula T  $x$  en el momento de la división celular y, por último,  $r_{i0}^1$  y  $r_{i0}^2$  denotan los valores iniciales de receptor  $R_i$  en las células hijas 1 y 2, respectivamente.

Una vez descritos los conceptos matemáticos que representan las hipótesis biológicas que sustentan este modelo, estamos en condiciones de estudiar las soluciones de las ecuaciones correspondientes y de interpretar, en términos biológicos, los resultados obtenidos. En el capítulo siguiente presentaremos simulaciones numéricas de este mismo modelo en un caso simplificado, en el que se supone que el número de receptores de membrana es dos ( $k = 2$ ). En ese capítulo se discutirán diferentes situaciones: tolerancia e intolerancia al patógeno o respuesta inmune en el caso de poblaciones de células T con distintas afinidades al patógeno. Todas estas situaciones han sido reproducidas a partir del mismo modelo, con el simple cambio del valor de sus parámetros, poniendo de manifiesto la capacidad del mismo para reproducir con facilidad situaciones diversas.

# Capítulo 4

## Simulaciones del modelo microscópico

A lo largo de este capítulo se expone en detalle cómo se han realizado las simulaciones del modelo descrito en la Sección 3.2. En este caso, se han realizado algunas simplificaciones para facilitar tanto la exposición como la implementación (ver Sección 4.1). En la Sección 4.2 se exponen algunas puntualizaciones básicas sobre la implementación de los algoritmos utilizados para las simulaciones de la Sección 4.3. Entre estas explicaciones se incluyen un pseudocódigo y aclaraciones sobre aspectos concretos del mismo. La versión completa del código principal de este capítulo, realizado en Matlab, puede verse en el Apéndice A. Como ya se ha comentado en el capítulo anterior, es posible ajustar los parámetros del modelo de manera que se pongan de manifiesto distintos comportamientos poblacionales. Concretamente se presentan situaciones de intolerancia al patógeno (Sección 4.3.1), en las que las células T erradican la población de patógeno, acabando así con la infección, situaciones de tolerancia (Sección 4.3.2), correspondientes al caso en el que las células T no consiguen controlar la infección y el agente que la produce se hace con el control del organismo, y se discute también qué ocurre cuando poblaciones de células T con distinta afinidad a un patógeno se enfrentan a él (Sección 4.3.3).

### 4.1. Modelo simplificado

Para las simulaciones hemos optado por una versión simplificada del modelo propuesto en la Sección 3.2, de tal manera que el número de parámetros sea suficiente para no perder la esencia del argumento, pero no muy elevado para evitar distraer al lector con notación engorrosa. Siguiendo con la notación de 3.2, asumiremos  $k = 2$ . Es decir, suponemos que hay dos tipos de receptores en la membrana de las células T:  $p$  (de proliferación) y  $d$  (de muerte) que controlan la evolución de los inhibidores de ciclo (Rb) y apoptosis (Bcl-2), respectivamente.

Distinguiremos dos tipos de células T: las efectoras, que son las que combaten activamente al patógeno, y las de memoria, que guardan información sobre el agente infeccioso con la finalidad de dar una respuesta inmune más rápida en caso de reaparición de este agente. Cada tipo de células constituye una población distinta, pues las ecuaciones que determinan su comportamiento son diferentes. Para las células T efectoras asumimos que los receptores de proliferación ( $p$ ) se expresan a partir de las señales que reciben gracias a su TCR y que, simultáneamente, autorregulan su expresión induciendo la producción de

receptores tipo muerte<sup>1</sup> ( $d$ ). Así las cosas, las ecuaciones 3.1 y 3.2 pueden escribirse como:

$$\left\{ \begin{array}{l} \dot{c}(t) = -\mu_{pc}p(t) \\ \dot{a}(t) = -\mu_{da}d(t) \\ \dot{p}(t) = \lambda_{Tp}r_T(t) - \lambda_{pp}p(t) \\ \dot{d}(t) = \lambda_{pd}p(t) \\ c(0) = c_0 \\ a(0) = a_0 \\ p(0) = p_0 \\ d(0) = d_0 \end{array} \right. \quad (4.1)$$

Para el caso de las células T de memoria hay que tener en cuenta que este tipo de células no muere durante la *contracción clonal*, es por ello que las ecuaciones que regulan esta población difieren ligeramente de las vistas en el Sistema 4.1. La dinámica de las células T de memoria viene dada por el mismo Sistema 4.1, en el que se ha tenido en cuenta que  $d = 0$ , puesto que nos centramos solamente en el inhibidor del ciclo celular y no en el de muerte. De esta manera, las ecuaciones que rigen el algoritmo de decisión para células T de memoria viene dado por:

$$\left\{ \begin{array}{l} \dot{c}(t) = -\mu_{pc}p(t) \\ \dot{p}(t) = \lambda_{Tp}r_T(t) - \lambda_{pp}p(t) \\ c(0) = c_0 \\ p(0) = p_0 \end{array} \right. \quad (4.2)$$

Con estos tres sistemas de ecuaciones (Sistemas 3.3, 4.1 y 4.2) queda definido el marco teórico del modelo. Sin embargo, antes de poder simular numéricamente estas ecuaciones debemos elegir los valores concretos que tomarán los parámetros. Esta no es una tarea sencilla, puesto que nadie sabe cuánto pueden valer estos coeficientes en la realidad. La elección de los parámetros que hemos hecho para la primera simulación (Sección 4.3.1) se recoge en la Tabla 4.1. En base a esta elección y a las variantes que se exponen a lo largo de esa sección, obtenemos unos resultados que nos permiten identificar distintos tipos de respuesta inmune, sin necesidad de invocar ningún mecanismo distinto a las hipótesis detalladas en la Sección 3.1. A continuación, se presentan algunos detalles de la implementación.

## 4.2. Detalles de implementación y pseudocódigo

Con ánimo de aclarar algunos aspectos técnicos, se especifican, paso por paso, las instrucciones seguidas para la realización de las simulaciones. El Algoritmo 1 contiene un pseudocódigo muy sencillo con los detalles claves y prácticamente independientes del lenguaje de programación que se utilice. El código completo, realizado en Matlab, puede verse en el Apéndice A.

La clave principal de la implementación es cómo se guarda la población de células disponibles en cada momento. Esta información se recoge en una matriz, donde se especifica el tipo de la célula (efectora, de memoria, si está en fase de ciclo, apoptosis o decisión)<sup>2</sup>,

<sup>1</sup>Esto no se produce en sentido contrario, los receptores tipo  $d$  no activan receptores de tipo  $p$ .

<sup>2</sup>Cada una de estas fases constituye un tipo distinto. Por ejemplo, una célula T efectora puede ser de tipo 1 si está en fase de decisión, 3 si está en fase de división o 4 si está en fase de apoptosis.

|                      |                                    |   |
|----------------------|------------------------------------|---|
| Variables            | $t_{cycle} = 0,15$                 | Duración de la fase de ciclo.                             |
|                      | $t_{apo} = 0,2$                    | Duración de la fase de apoptosis.                         |
|                      | $t_{next} = 0,3$                   | Duración del paso en la simulación.                       |
|                      | $a_0 = 0,3$                        | Cantidad inicial de Bcl-2 para células T efectoras.       |
|                      | $c_0 = 0,08$                       | Cantidad inicial de Rb para células T efectoras.          |
|                      | $c_0^{mem} = 0,04$                 | Cantidad inicial de Rb para células T de memoria.         |
|                      | $N_{ini} = 25$                     | Número inicial de células T naïve.                        |
|                      | $Y_{ini} = 5$                      | Número inicial de moléculas del patógeno.                 |
|                      | $r_p, r_d = 0$                     | Número inicial de receptores de membrana $p$ y $d$ .      |
| Patógeno             | $\alpha = 6$                       | Tasa de proliferación.                                    |
|                      | $\beta = 0,04$                     | Tasa de muerte por linfocito.                             |
| Células T efectoras  | $\lambda_{pd} = 0,05$              | Tasa de cambio del receptor $R_d$ por cada señal $R_p$ .  |
|                      | $\lambda_{Tp} = 6 * 10^{-5}$       | Tasa de cambio del receptor $R_p$ por cada señal del TCR. |
|                      | $\lambda_{pp} = 0,5 * 10^{-4}$     | Tasa de cambio del receptor $R_p$ por cada señal $R_p$ .  |
|                      | $\mu_{pc} = 15$                    | Tasa de cambio de Rb por cada señal del TCR.              |
|                      | $\mu_{da} = 10$                    | Tasa de cambio de Bcl-2 por cada señal del TCR.           |
|                      | $\lambda_{Tp}^{mem} = 10^{-5}$     | Igual que $\lambda_{Tp}$ , para células T de memoria.     |
| Células T de memoria | $\lambda_{pp}^{mem} = 2 * 10^{-2}$ | Igual que $\lambda_{pp}$ , para células T de memoria.     |
|                      | $\mu_{pc}^{mem} = 13$              | Igual que $\mu_{pc}$ , para células T de memoria.         |

Tabla 4.1: Tabla de variables y parámetros.

la cantidad de Rb y Bcl-2 disponible, el número de receptores de membrana que tiene y el tiempo que le queda para finalizar la fase correspondiente. Como se trata de un modelo microscópico, en el que cada célula toma su decisión de manera independiente, el hilo conductor de la implementación se basa en recorrer la matriz de células y ejecutar la decisión tomada por la célula que se esté tratando. Cada vez que se recorre la población de células T asumimos que pasa un tiempo  $t_{next}$  que actualiza el tiempo actual de la simulación al final de la iteración y que permite determinar cuándo una célula ha acabado la fase de división o apoptosis. Una vez establecidas las estructuras necesarias para guardar la información, veamos las instrucciones concretas del modelo.

1. Comenzamos la simulación en un tiempo inicial  $t = 0$  y acabamos en un tiempo final  $T_{final}$  configurable.
2. Para cada tiempo  $t$ , se calcula la cantidad de patógeno disponible,  $Y$ .
3. En función de  $Y$ , y para cada célula T de la población, se calcula la cantidad de patógeno que está a su alcance y se resuelve el sistema de ecuaciones correspondiente

para conocer la cantidad de Rb ( $c$ ) y Bcl-2 ( $a$ ) activa en ese instante. En función de esto se desencadena la división celular, si  $c = 0$ , o el suicidio de la célula, si  $a = 0$ . En otro caso la célula seguirá en fase de decisión y volverá a calcular  $a$  y  $c$  en la siguiente iteración en base a la cantidad obtenida en la actual.

4. Cuando una célula se divide, se generan dos células hijas con los parámetros correspondientes a sus receptores (ver Sistema 3.6). Recordemos que la cantidad de receptores de la célula madre se divide entre las dos hijas de manera asimétrica, y los parámetros iniciales, para que pueda comenzar su fase de *decisión*. Se sigue en el paso 6.
5. Si por el contrario la célula comete suicidio, se eliminará de la población.
6. Se contempla la siguiente célula de la población y se vuelve a 3.
7. Se actualiza el tiempo para la siguiente iteración y se vuelve a 1.

---

**Algorithm 1** Algoritmo de la decisión. Células T.

---

```

1: Inicialización de parámetros según 4.1
2:  $t = 0$ ;                                ▷ t será el tiempo por el que vamos simulando
3: while  $t < T_{final}$  do
4:    $Y = Y_{init} * e^{t*(\alpha - N*\beta)}$ ;      ▷ Calculamos Y con la solución explícita de 3.3
5:   for  $nCell$ ;  $nCell++$ ;  $N$  do              ▷ Para cada célula T de la población
6:      $r_T = \rho * Y$ ;                          ▷ Ecuación 3.4
7:     if  $efectora(nCell)$  then                ▷ Si es una célula T efectora
8:       Se resuelve 4.1
9:       if  $a \leq 0$  then
10:        La célula  $nCell$  se elimina de la población
11:       else if  $c \leq 0$  then
12:        La célula  $nCell$  se divide
13:        Las condiciones iniciales de las células hijas vienen determinadas por
            $a_0, c_0$  y 3.6
14:       else if  $memoria(nCell)$  then          ▷ Si es una célula T de memoria
15:        Se resuelve 4.2
16:       if  $c \leq 0$  then
17:        La célula  $nCell$  se divide siguiendo el mismo procedimiento que la divi-
           sión de una célula T efectora.
18:    $t = t + t_{next}$ ;
19:   Se actualiza el número de células de la población.

```

---

En este pseudocódigo se ha detallado cuáles son las ecuaciones involucradas en cada paso. A continuación, exponemos algunas particularidades de este pseudocódigo: hemos omitido que cuando las condiciones son  $a > 0$  y  $c > 0$ , en el caso de las células T efectoras y  $c > 0$ , en el caso de las células T de memoria, la célula permanece en la fase de decisión, pero actualiza sus condiciones para la siguiente iteración según los resultados que ha obtenido en la iteración actual. También hay que tener en cuenta que la división celular y el proceso de apoptosis no se llevan a cabo de manera inmediata, conllevan un tiempo  $t_{cycle}$  y  $t_{apo}$ , respectivamente, por lo que el número total de células en la población debe actualizarse una vez que estos procesos hayan finalizado y no instantáneamente, como pueden sugerir las líneas 10, 12 y 17 del pseudocódigo. Otro aspecto que hemos supuesto es que el parámetro



$\gamma$  que aparecía en la Ecuación 3.4 es  $\gamma = 1$ . Es decir, suponemos que todo encuentro del TCR de la célula T con el antígeno va a desencadenar una activación. El parámetro  $\rho$  debe ser calculado de tal manera que todas las células T tengan las mismas posibilidades a la hora de interaccionar con el patógeno. En la implementación real se usó un vector de números aleatorios entre 0 y 1 normalizado respecto del número total de células T. Buena parte de la notación usada en el Algoritmo 1 ya ha sido introducida a lo largo de este trabajo, pero volvemos a insistir en que  $Y$  representa el número de moléculas del patógeno, mientras que  $N$  representa la cantidad total de células T, incluyendo las efectoras y las de memoria. Sin embargo, en la implementación real, en la línea 4 del pseudocódigo, el  $N$  utilizado es solamente el número total de células T efectoras, sin contar las de memoria<sup>3</sup>.

### 4.3. Resultados y análisis


En esta sección expondremos los resultados de las simulaciones realizadas. Comenzaremos discutiendo dos situaciones básicas que se pueden dar en una infección: que las células inmunes logren eliminar la infección o que, por el contrario, sea el agente infeccioso el que acabe tomando el control de nuestro organismo, y acabaremos mostrando el resultado de diversas simulaciones cuando la afinidad por el patógeno de las células T va variando.

#### 4.3.1. Intolerancia al patógeno

Se entiende como situación de intolerancia al patógeno aquella en la que las células T son capaces de controlar la infección y eliminar por completo al agente infeccioso. La simulación correspondiente a este caso puede verse en la Figura 4.1a. En la figura se puede observar que el patógeno, representado con una línea roja, crece rápidamente, debido a la elección de una tasa de crecimiento,  $\alpha$ , elevada. Una vez que las células T son conscientes de la rápida proliferación de un agente no deseado, su número comienza a crecer. Esto se debe a que  $p$  se incrementa ( $r_T(t)$  es más grande puesto que hay más patógeno), provocando que  $c(t)$  alcance rápidamente el umbral  $c(t) = 0$  y desencadenando la división celular. Sin embargo, como ya habíamos comentado anteriormente, esto se produce con cierto retraso tras la aparición del patógeno. Lo que estamos describiendo es la conocida *expansión clonal*. Este crecimiento de células T provoca que el término que acompaña a  $\beta$  en la Ecuación 3.3 comience a ser más grande que el acompañado por  $\alpha$  en esta misma ecuación, causando así que la derivada de  $y$  se haga negativa y, por tanto, el número de células del patógeno comience a decrecer. Debemos mencionar que el número de células T necesarias para eliminar al patógeno viene regulado por el parámetro  $\beta$  (siempre que el resto de parámetros permanezcan inalterados), si este fuera más grande, es decir, si las células T fueran más dañinas con el patógeno, el número de células T necesarias para controlar la infección sería menor (y viceversa). Debido a que los receptores de proliferación,  $p$ , autorregulan los receptores de muerte,  $d$ , se observa cómo, tras el aumento en el número de células T, le sigue la *contracción clonal*, restaurando así los niveles de población.

Prestemos atención ahora al comportamiento de las células T de memoria: por la sección anterior, ya sabíamos que las células T efectoras y las de memoria iban a constituir poblaciones distintas, puesto que las ecuaciones que rigen sus dinámicas son distintas. La principal diferencia es que las células T de memoria no se suicidan una vez el patógeno ha

<sup>3</sup>Esto se ha hecho así porque el proceso que siguen las células T de memoria es más complejo que lo que se recoge en el modelo. Estas células al cabo de un tiempo se desactivan y para que tengan un efecto sobre el patógeno deben volver a activarse. Para intentar hacer el modelo lo más sencillo posible se ha optado por hacer que las únicas células que combaten al patógeno sean las T efectoras.



(a) Simulación: caso de intolerancia al patógeno. Los parámetros son los expuestos en la Tabla 4.1.

(b) Simulación: caso de tolerancia al patógeno. Los parámetros son los mismos que se exponen en la Tabla 4.1, excepto:  $\alpha = 1$ ,  $\beta = 0,01$ ,  $\mu_{pc} = 3$ ,  $\mu_{da} = 2$ ,  $\mu_{pc}^{mem} = 2$ .

Figura 4.1: Simulaciones del modelo microscópico. Casos de intolerancia y tolerancia al patógeno

desaparecido, sino que permanecen con la información necesaria para atacar al patógeno más rápidamente en caso de reaparición. En la Figura 4.1a vemos cómo estas células de memoria aumentan su población tras la aparición del patógeno, aunque no se produce un crecimiento tan rápido ni elevado como en el caso de las T efectoras. Su población queda reducida a un 5 – 10 % de la población de células T.

#### 4.3.2. Tolerancia al patógeno

Hemos visto en la sección anterior una simulación de intolerancia al patógeno. Esto es, hemos considerado el caso en que las células inmunes consiguen controlar la infección y erradicar por completo al agente infeccioso. Sin embargo, esto no es siempre así. Existen *patógenos*, como la bacteria *Mycobacterium Tuberculosis*<sup>4</sup>, que han desarrollado una estrategia que consiste en crecer a un ritmo muy lento. De esta manera *sigilosa* engañan a las células T, haciéndolas creer que su población ha sido erradicada y provocando que estas células inmunes se suiciden (Leggett et al., 2017).

Como se puede ver en la Figura 4.1b, las células T comienzan la *expansión clonal* como respuesta a la presencia de patógeno, al igual que en el caso anterior. Este aumento de población inmune hace que la población del patógeno se vea afectada rápidamente (recordemos que su factor de crecimiento,  $\alpha$ , es pequeño en este caso) y caiga hasta niveles muy bajos. Es entonces cuando las células inmunes perciben que el patógeno ha sido eliminado con éxito y comienzan la *contracción clonal*, haciendo que su población baje hasta desaparecer (recordemos que los receptores de muerte ( $d$ ) no inducen la formación de receptores de proliferación ( $p$ )). Sin embargo, debido a que el patógeno no ha sido erradicado por completo, y ahora que la población de células T ha iniciado su fase de *apoptosis*, este puede reproducirse sin problema, dando lugar al crecimiento exponencial que vemos en la Figura 4.1b. En poco tiempo estos *patógenos astutos* pueden tomar el

<sup>4</sup><https://www.omicsonline.org/open-access/why-is-mycobacterium-tuberculosis-hard-to-grow-the-principle-of-1000176.php?aid=26260>  
<https://www.britannica.com/science/bacteria/Growth-of-bacterial-populations>

control del organismo.

En cuanto a las células T de memoria, vemos como crecen con la presencia del patógeno. Una vez que la población de células T efectoras llega a cero el número de estas células se estabiliza, puesto que las células T de memoria no continúan reproduciéndose en ausencia de células T efectoras, a pesar de la presencia de patógeno. Esto se debe a que las células T de memoria necesitan señales de proliferación para reproducirse y estas son generadas por las células T efectoras.

### 4.3.3. Simulaciones con distintas poblaciones de células T

En esta sección veremos cómo se comportan distintas poblaciones de células T efectoras frente a un mismo patógeno, cuando presentan afinidades dispares al agente infeccioso. Además, veremos cómo se comportan estas poblaciones cuando la población *immunodominante*<sup>5</sup> desaparece.

Comencemos considerando la Figura 4.2a. En esta simulación hemos considerado tres poblaciones con distinta afinidad,  $\lambda_{Tp}$ , al patógeno. Tenemos el clon 0 con la afinidad más alta y el clon 2 con la más baja. La diferencia en cuanto a expansión es considerable, la población más afín al patógeno es la que se reproduce a mayor velocidad y se denomina *población immunodominante*. Este hecho es consecuencia de las ecuaciones del Sistema 4.1: la ecuación  $\dot{p}(t) = \lambda_{Tp}r_T(t) - \lambda_{pp}p(t)$  propicia un mayor crecimiento cuanto más alto es el valor  $\lambda_{Tp}$ , puesto que provoca que la derivada de  $c$  se haga más negativa y se llegue antes al límite  $c = 0$  que desencadena la división celular.


Pero... ¿qué pasaría si esta *población immunodominante* desapareciera? Una posible explicación nos la da la Figura 4.2b. En ella, podemos ver que el modelo sugiere que las *poblaciones subdominantes* se expanden más que antes para suplir la ausencia de la *immunodominante* y controlar la infección. No debemos olvidar que la afinidad que tienen estas poblaciones al patógeno es menor y esto hace que este pueda crecer más en el mismo periodo de tiempo.

Para finalizar veamos el comportamiento del clon 2 cuando el resto de clones han desaparecido. Como es de esperar, ocurre algo similar a lo que veíamos en la Figura 4.2b. En este caso el clon 2 debe hacer un esfuerzo mayor (reproducirse más) para mantener la infección controlada. El comportamiento correspondiente está ilustrado en la Figura 4.2c.


Estas simulaciones ponen de manifiesto la importancia de las células T de memoria. En una situación donde las células T efectoras no presentan una afinidad al patógeno muy elevada las consecuencias pueden ser muy graves, pues la infección se alarga y las células T no son suficientemente dañinas para el agente externo. Sin embargo, si contamos con células T de memoria que guardan información relevante para combatir a ese agente, nuestro organismo se encontrará en una situación más segura, ya que se podrá actuar más rápidamente con células que disponen de alta afinidad con el patógeno y desencadenarán, por tanto, un ataque mucho más efectivo.

---


<sup>5</sup>La población *immunodominante* es aquella que presenta la afinidad más alta con el patógeno.



(a) Simulación: distintas poblaciones de células T con distintas afinidades al patógeno. Clones subdominantes. Los parámetros son los mismos que se exponen en la Tabla 4.1, excepto:  $\lambda_{Tp}^{clon0} = 2 * 10^{-4}$ ,  $\lambda_{Tp}^{clon1} = 6 * 10^{-5}$ ,  $\lambda_{Tp}^{clon2} = 10^{-5}$ .



(b) Simulación: distintas poblaciones de células T con distintas afinidades al patógeno. Clones subdominantes. Los parámetros son los mismos que se exponen en la Tabla 4.1, excepto:  $\lambda_{Tp}^{clon1} = 6 * 10^{-5}$ ,  $\lambda_{Tp}^{clon2} = 10^{-5}$ .



(c) Simulación: distintas poblaciones de células T con distintas afinidades al patógeno. Clon subdominante. Los parámetros son los mismos que se exponen en la Tabla 4.1, excepto:  $\lambda_{Tp}^{clon2} = 10^{-5}$ .

Figura 4.2: Simulaciones del modelo microscópico. Poblaciones de células T con distinta afinidad al patógeno.

# Capítulo 5

## Modelo macroscópico para la dinámica de población de las células T durante la respuesta inmune.

En este capítulo se expone otro modelo matemático propuesto para determinar el algoritmo de decisión entre división o apoptosis de las células T durante una respuesta inmune (ver Sección 2.2.1). En esta área aún son muchas las cuestiones que quedan por resolver: una vez que las células se activan, ¿hasta cuándo continúan dividiéndose?, ¿es esta decisión totalmente dependiente de las condiciones que hayan tenido las células en el momento de su activación?, ¿por qué hay un retraso respecto a la desaparición del patógeno en la *contracción clonal*?... Estas cuestiones se abordaron en el Capítulo 3, donde se establece la base teórica de un modelo matemático a nivel microscópico. Es decir, este modelo proporciona el algoritmo de decisión para cada célula, pues las decisiones de las células inmunes son, *a priori*, independientes unas de otras (no se ha encontrado un órgano que regule estos mecanismos (Arias y Herrero, 2016)).

En este capítulo lo que haremos será volver sobre este mismo problema, pero desde una perspectiva un poco distinta, desde un punto de vista macroscópico. Esto quiere decir que las ecuaciones diferenciales sobre las que se basa el modelo determinan el comportamiento de toda la población de células. Para entender esto podemos poner como ejemplo los movimientos de un equipo de fútbol: la estrategia de contraataque del equipo vista desde el punto de vista «macroscópico» sería recuperar el balón y avanzar rápidamente al campo del adversario para marcar gol. Sin embargo, si nos fijamos ahora en el mundo «microscópico» de cada jugador, vemos que cada uno tiene su papel, defender y recuperar la posesión, pasar a los centrales o a los delanteros, etc.

Al comienzo de este capítulo, la Sección 5.1 desgrana las dos características poblacionales, inercia y elasticidad, sobre las que se sustenta el modelo y se detallan las ecuaciones que rigen la dinámica de población de las células T y del patógeno. En la sección siguiente (Sección 5.2), se realizan simulaciones de este modelo y se comparan los resultados con los del modelo microscópico.

### 5.1. Inercia y elasticidad en las células T

Como ya se avanzaba en la introducción de este capítulo, nos centraremos en dos características de la dinámica de población de las células T: la elasticidad (la población se

expande y se contrae, dando lugar a lo que se conoce como *expansión* y *contracción clonal* y la inercia (la *contracción clonal* se presenta con retraso tras la desaparición del patógeno) (Arias et al., 2015). En base a estas dos propiedades, se detallan las ecuaciones que dan lugar a este modelo matemático. El modelo consta de un sistema de ecuaciones diferenciales de segundo orden. Este tipo de ecuaciones constituye la manera más simple de representar la inercia de la población (Arias et al., 2015). Además, las ecuaciones de segundo grado son el marco general para las dinámicas *newtonianas*. Esto nos lleva a modelar de manera natural la dinámica de las células T efectoras como el balance entre dos fuerzas opuestas actuando sobre la población: una fuerza por parte del *antígeno* causada por la presencia del patógeno y una fuerza intrínseca elástica que devuelve a la población a su estado inicial. En concreto, asumiremos que la fuerza que ejerce el *antígeno* es proporcional al número de células del patógeno y modelaremos la elasticidad mediante la *Ley de Hooke*, que establece que la fuerza necesaria para restablecer el equilibrio una vez que la población ha llegado a cierto valor es proporcional a dicho valor (Arias et al., 2015). También asumiremos que el patógeno prolifera con una ratio constante y que serán eliminados por la acción de las células T de manera proporcional a sus encuentros mutuos. De esta manera, presentamos el siguiente modelo:

$$\begin{cases} T''(t) = -kT(t) + \lambda P(t) \\ P'(t) = \alpha P(t) - \beta T(t)P(t) \\ T(0) = 0 \\ T'(0) = 0 \\ P(0) = P_0 \geq P_m \end{cases}, \text{ para } T \geq 0, P \geq P_m \quad (5.1)$$

donde  $T(t)$  y  $P(t)$  son el número de células T efectoras y el número de células de patógeno, respectivamente. La primera ecuación diferencial que nos encontramos nos sugiere que, en ausencia de patógeno, la población de células T se puede caracterizar por una respuesta elástica en forma de soluciones oscilatorias. Así mismo, la presencia de patógeno tendría el efecto de una fuerza externa. Siguiendo con la segunda ecuación, observamos que, en ausencia de células T, la población de patógeno crece de manera exponencial. Sin embargo, una vez que las células T entran en acción empiezan a eliminar al patógeno de acuerdo a posibles encuentros entre  $T(t)$  y  $P(t)$  (Arias y Herrero, 2016). La eficiencia de cada proceso se mide en base a cuatro parámetros y las condiciones iniciales del sistema. Estos parámetros son  $\alpha$ ,  $\beta$ ,  $k$  y  $\lambda$ . Los dos primeros representan la tasa de crecimiento del patógeno y la tasa de eliminación del mismo a causa de las células T, respectivamente. Por su parte  $k$  y  $\lambda$  representan las constantes de elasticidad e inercia de la población, respectivamente.

El Sistema 5.1 también puede expresarse de manera adimensional, reduciendo el número de parámetros a dos:

$$\begin{cases} T''(t) = -T(t) + P(t) \\ P'(t) = \alpha^* P(t) - \beta^* T(t)P(t) \\ T(0) = 0 \\ T'(0) = 0 \\ P(0) = 1 \end{cases}, \text{ para } T \geq 0, P \geq P_m^* \quad (5.2)$$

Donde  $\alpha^* = \frac{\alpha}{\sqrt{k}}$ ,  $\beta^* = \frac{\beta \lambda P_0}{k \sqrt{k}}$  y  $P_m^* = \frac{P_m}{P_0}$ .

En lo que sigue estudiaremos el comportamiento de estos dos sistemas mediante una




Figura 5.1: Simulación del modelo macroscópico. Caso de intolerancia al patógeno. Parámetros:  $\alpha = 1,5$ ,  $\beta = 0,1$ ,  $k = 4$ ,  $\lambda = 0,5$ ,  $P_m = 0$ .

serie de simulaciones numéricas, pues en este caso las ecuaciones no tienen una solución explícita.

## 5.2. Simulaciones del modelo macroscópico


A continuación, presentaremos distintas situaciones que se pueden dar con la simple variación de los parámetros del modelo macroscópico visto en la sección anterior. Para poder comparar estos resultados, se simulan las situaciones de tolerancia e intolerancia vistas en el Capítulo 4 para el modelo microscópico y veremos cómo los parámetros  $\alpha^*$  y  $\beta^*$  del Sistema 5.2 nos revelan la dependencia crucial que tienen sobre el modelo en estas dos situaciones.

El código referente a esa sección puede verse en el Apéndice A.


### 5.2.1. Intolerancia al patógeno

Como vimos en la Sección 4.3.1, el caso de intolerancia al patógeno se da cuando las células inmunes consiguen eliminar al agente que causa la infección. En este tipo de simulaciones vemos como el patógeno aumenta su población seguido de una rápida proliferación de las células T (*expansión clonal*), cuya acción erradica al patógeno. Posteriormente a la desaparición del patógeno, y con cierto retraso, tiene lugar la *contracción clonal*, que restaura los niveles de población de células T. En la Figura 5.1, correspondiente a a simulación del Sistema 5.1, podemos ver esta situación gráficamente.


Queda, por tanto, de manifiesto la característica de inercia, pues se ve cómo las células T comienzan a disminuir en número después de que el patógeno haya desaparecido, y de elasticidad, pues la población de células T acaba recuperando sus niveles iniciales. Como vemos, el parecido de esta figura con la Figura 4.1a es notable, ambos modelos, macroscópico y microscópico, simulan el mismo comportamiento desde dos puntos de vista distintos.



(a) Simulación: caso de tolerancia al patógeno en el modelo macroscópico. Parámetros:  $\alpha = 0,05$ ,  $\beta = 0,1$ ,  $k = 0,25$ ,  $\lambda = 0,15$ ,  $P_m = 0$ .



(b) Simulación: caso de tolerancia al patógeno en el modelo macroscópico adimensional. Parámetros:  $\alpha^* = 1,1$ ,  $\beta^* = 0,01$ ,  $P_m^* = 0$ .



(c) Simulación: caso de tolerancia al patógeno con recaída en la infección en el modelo macroscópico. Parámetros:  $\alpha = 0,4$ ,  $\beta = 0,008$ ,  $k = 0,25$ ,  $\lambda = 0,2$ ,  $P_m = 0$ .

Figura 5.2: Simulaciones del modelo macroscópico. Casos de tolerancia al patógeno

### 5.2.2. Tolerancia al patógeno

Veamos ahora al caso análogo a la Sección 4.3.2, donde vimos cómo un patógeno con una tasa de reproducción pequeña conseguía zafarse de las células T. En la Figura 5.2a, se ha simulado el Sistema 5.1 con una tasa de reproducción,  $\alpha$ , pequeña respecto a la tasa de eliminación del patógeno,  $\beta$ . Al comienzo, las células T se reproducen rápidamente para controlar la infección, haciendo que la población de patógeno apenas pueda crecer. Sin embargo, cuando empieza la *contracción clonal* se observa que el patógeno consigue escapar del ataque de las células T, cuya población desaparece. Esto se produce porque la fuerza que ejerce el patógeno no es suficiente para contrarrestar la fuerza elástica de las células T, provocando que la población de células T desaparezca irremediabilmente. Un comportamiento análogo puede verse en la Figura 5.2b. En este caso se ha simulado el Sistema 5.2 con una tasa de reproducción,  $\alpha^*$ , elevada respecto a la tasa de eliminación del patógeno,  $\beta$ , al contrario que en el caso anterior. A pesar de ello, tenemos también un comportamiento de tolerancia, lo que sugiere que se necesita un valor mayor de estos



parámetros para salir de la región de tolerancia (ver Sección 5.2.3).

Por su parte, en la Figura 5.2c se puede observar un comportamiento de tolerancia en el que ha tenido lugar una recaída de la infección. Tras la primera *expansión clonal* de las células T, le sigue la *contracción clonal*, sin embargo, en este caso, la tasa de reproducción del patógeno,  $\alpha$ , y el número de células del patógeno aún existentes son suficientes para contrarrestar la fuerza elástica de las células T,  $k$ , provocando así que vuelva a aumentar la población de estas últimas, repitiendo el proceso. Al contrario que en la ocasión anterior y debido a que el número de células del patógeno es menor, puede verse que el mecanismo de *contracción clonal* termina, eliminando a todas las células T y permitiendo el libre crecimiento del patógeno, que crece de manera exponencial.

### 5.2.3. Regiones de tolerancia e intolerancia

Es interesante analizar la relación que existe entre el valor de los parámetros del modelo y las regiones de intolerancia y tolerancia. Este asunto se ha abordado para el modelo macroscópico adimensional (ver Sistema 5.2). Para ello se ha implementado un programa que recorre los valores de  $\alpha^*$  y  $\beta^*$  entre 0,1 y 2,5 con un paso de 0,1<sup>1</sup>, y, para cada valor, simula el Sistema 5.2. Una vez hecha la simulación se observa el número de células T y de patógeno para obtener el resultado de tolerancia, en caso de que las células T no consiguen acabar con el patógeno o intolerancia en caso contrario. La Figura 5.3 recoge el resultado de todas estas simulaciones, arrojando datos importantes: si dejamos uno de los dos parámetros fijos, es posible cambiar de una región a otra con tan solo modificar el otro parámetro. De hecho, de acuerdo con este modelo, patógenos (y tumores) pueden escapar de la acción de las células T por dos métodos: reduciendo el efecto de las células T, el parámetro  $\beta^*$ , o reduciendo su tasa de proliferación, el parámetro  $\alpha^*$ , (Arias y Herrero, 2016). Una consecuencia que se puede extraer de esto es que mecanismos como la fiebre, que incrementa la tasa de proliferación del patógeno, o la inflamación, que aumenta la acción de las células T, favorecen que el patógeno sea vencido.




Figura 5.3: Simulación del modelo macroscópico adimensional. Variación de los parámetros  $\alpha^*$  y  $\beta^*$  para dar lugar a regiones de tolerancia e intolerancia al patógeno.

<sup>1</sup>Con paso nos referimos al valor del incremento del parámetro en cada iteración.



# Capítulo 6

## Correspondencia de parámetros entre los modelos microscópico y macroscópico

En los Capítulos 3 y 5 se establece el marco teórico de dos modelos matemáticos que dan una posible explicación del mecanismo que rige la dinámica de población de las células T durante una infección aguda. Como se puede ver en las simulaciones correspondientes de estos modelos (ver Capítulo 4 y Sección 5.2) ambos pueden reproducir comportamientos similares, como son el de tolerancia e intolerancia al patógeno. Sin embargo, ambos modelos son notablemente distintos por dos razones:

1. El punto de vista desde el cual se aborda el algoritmo de decisión de las células T es distinto. Mientras que el modelo microscópico describe el algoritmo de comportamiento de cada célula de manera individual, el macroscópico propone unas ecuaciones que gobiernan sobre toda la población de células.
2. Las ecuaciones diferenciales que conforman el modelo microscópico son de primer orden y su significado, desde el punto de vista biológico está bien definido. En concreto, los parámetros de este modelo, tales como el número de receptores de membrana de la célula ( $r_i$ ) o la tasa de cambio de estos receptores ( $\lambda_{xy}$ ) (ver Tabla 4.1), representan conceptos biológicos claros. Por su parte, el modelo macroscópico utiliza un sistema de ecuaciones de segundo grado, basado en las dinámicas newtonianas y en dos propiedades de la población: la elasticidad y la inercia. Los parámetros  $k$  y  $\lambda$  representan estas dos últimas propiedades en las ecuaciones, respectivamente. Sin embargo, desde el punto de vista biológico, el valor de estos parámetros tiene un significado meramente fenomenológico y su justificación experimental es una cuestión abierta.

A pesar de que el número de parámetros del modelo macroscópico es considerablemente menor, la elección de los parámetros  $k$  y  $\lambda$  es más compleja que la de los parámetros del modelo microscópico por la razón 2. Así las cosas, lo ideal sería poder establecer una correspondencia entre los parámetros de ambos modelos. De esta manera se podrían establecer los valores de los parámetros del modelo microscópico, que tienen un significado biológico claro, e inferir el valor de los parámetros del modelo macroscópico o viceversa. A lo largo de este capítulo se detalla cómo se ha abordado un aspecto concreto de este problema mediante el uso de técnicas de inteligencia artificial (Sección 6.1) y se interpretan los resultados obtenidos (Sección 6.2).

## 6.1. Conjunto de datos y entrenamiento de la red neuronal


Como una primera aproximación a esta cuestión de correspondencia de parámetros, se propone la implementación de una red neuronal cuyo propósito es predecir el valor de los parámetros que se le deben asignar al modelo macroscópico teniendo como entrada aspectos característicos de una simulación. En otros términos, se podría decir que se busca hacer la función inversa del modelo. Una vez hecho lo anterior, podemos hacer una simulación con unos parámetros concretos del modelo microscópico, extraer los puntos clave de la misma, y obtener el valor de los parámetros del modelo macroscópico que se deberían usar para lograr un resultado similar.

Antes de poder implementar la red es necesario determinar con qué datos se va a trabajar. Más concretamente se deben establecer las entradas y las salidas que tendrá la red. En nuestro caso, nos limitaremos al estudio del siguiente caso particular.


- Las simulaciones que se realizan para obtener los datos pertinentes se corresponden con situaciones de intolerancia al patógeno.
- La red neuronal consta de diez datos de entrada y cuatro de salida. Los seis primeros datos de entrada se corresponden con seis puntos de interés de cada simulación. Estos puntos son: el máximo número de células de patógeno alcanzado, el máximo número de células T alcanzado, el tiempo en el que se obtuvieron ambos y el tiempo en el que desaparecieron ambas poblaciones (en la Figura 6.3a pueden verse destacados los puntos mencionados), que denominaremos como  $max\_P$ ,  $max\_T$ ,  $t\_max\_P$ ,  $t\_max\_T$ ,  $t\_min\_P$ ,  $t\_min\_T$ , respectivamente. Los cuatro restantes datos de entrada son los parámetros  $\alpha$ ,  $\beta$ ,  $k$  y  $\lambda$  del modelo macroscópico con los cuales se han obtenido los seis valores anteriores. Por último, los cuatro parámetros de salida de la red se corresponden con los valores de los parámetros  $\alpha$ ,  $\beta$ ,  $k$  y  $\lambda$  predichos por la misma.
- El rango de valores para  $\alpha$ ,  $\beta$ ,  $k$  y  $\lambda$  se estableció con ayuda del modelo macroscópico adimensional (ver Figura 5.3), para ajustarnos lo más posible a una situación de intolerancia, y de tal manera que el número de simulaciones resultantes no fuera demasiado elevado, pero permitiendo suficiente variabilidad en los datos para abarcar el mayor número posible de situaciones. En concreto, se establecieron los siguientes rangos:
  - $\alpha \in [0, 75; 7]$
  - $\beta \in [0, 1; 5]$
  - $k, \lambda \in [0, 1; 2]$

Con estos rangos y a un paso<sup>1</sup> de 0,5 se obtienen unas 2080 simulaciones aproximadamente, de las cuales 1587 fueron casos de intolerancia. Los valores correspondientes a los puntos de interés de la simulación y sus parámetros se recogen en el archivo *data\_neural\_network\_csv* por filas y en el mismo orden que han sido mencionados ( $max\_P$ ,  $max\_T$ ,  $t\_max\_P$ ,  $t\_max\_T$ ,  $t\_min\_P$ ,  $t\_min\_T$ ,  $\alpha$ ,  $\beta$ ,  $k$  y  $\lambda$ ). Este documento da lugar al conjunto de datos de la red.

<sup>1</sup>Con paso nos referimos al valor del incremento del parámetro en cada iteración.



(a) Esquema de una red neuronal con cuatro capas densas.



(b) Esquema de un nodo de una red neuronal.

Figura 6.1: Representación esquemática de una red neuronal.

### 6.1.1. Aspectos técnicos de la red

Una red neuronal está compuesta por un conjunto de neuronas interconectadas entre sí mediante enlaces. Cada neurona toma como entradas las salidas de las neuronas de las capas antecesoras, cada una de esas entradas se multiplica por un peso, se agregan los resultados parciales<sup>2</sup> y mediante una función de activación se calcula la salida. Esta salida es a su vez es entrada de la neurona a la que precede. En la Figura 6.1a se ilustra la estructura de una red con dos capas ocultas (*hidden layer*), una capa de entrada (*input layer*) y otra de salida (*output layer*). Todas ellas son capas densas, es decir, están totalmente conectadas. En la Figura 6.1b podemos ver el esquema de cada neurona o nodo.

En nuestro caso, la red cuenta con cinco capas densas y activaciones *ReLU*<sup>3</sup> (Esto es importante en la última capa, puesto que los parámetros no pueden tomar valores negativos). Como es habitual para el entrenamiento de una red neuronal, el 70 % del conjunto de los datos, tomado de forma aleatoria, se utilizó para el entrenamiento y el 30 % restante para *testear* la red<sup>4</sup>. La implementación de la red está realizada en Python y el código correspondiente puede verse en el archivo *redNeuronal\_modeloMacro.py*.

## 6.2. Resultados obtenidos por la red neuronal


En esta sección se exponen los resultados obtenidos tras el entrenamiento de la red. Además, veremos un ejemplo real de la inferencia de parámetros dada por la red tras establecer como entrada una simulación del modelo microscópico.

Comencemos definiendo los conceptos de *epoch*, *loss* y *accuracy* para una red neuronal. Se entiende por *epoch* cada pasada completa por todo el conjunto de datos de entrenamiento. Las redes neuronales, cuando entrenan, hacen varias pasadas por los datos y, en cada una de ellas, intentan minimizar una función de error. El concepto de *loss* está asociado a

<sup>2</sup>Se suman las entradas multiplicadas por sus pesos asociados.

<sup>3</sup> $ReLU(x) = \max(0, x)$

<sup>4</sup>Entrenar una red neuronal consiste en ajustar cada uno de los pesos de las entradas de todas las neuronas que forman parte de la red neuronal, para que las respuestas de la capa de salida se ajusten lo más posible a los datos que conocemos. *Testear* una red neuronal consiste en observar cómo se comporta la red cuando los datos que tiene como entrada son distintos a los datos de entrada recibidos durante el entrenamiento. En esta fase los pesos de la red son los hallados tras el entrenamiento.



(a) Valores de *loss* calculados para la red neuronal durante el entrenamiento.

(b) Valores de *accuracy* calculados para la red neuronal durante el entrenamiento.

Figura 6.2: Representación gráfica de los valores de *loss* y *accuracy* para cada *epoch* durante el entrenamiento de la red.

esto último, pues este es el valor que intentamos minimizar. Cuanto más pequeño es más precisas son las predicciones de la red. En nuestro caso, el valor de *loss* se corresponde con el error cuadrático medio. Por su parte, el valor de *accuracy* es una métrica utilizada para medir el rendimiento del algoritmo. Este valor se calcula una vez la red se ha entrenado y han fijado todos sus parámetros. El valor de *accuracy* mide cómo de preciso es el modelo comparado con los datos reales. Por ejemplo, supongamos que tenemos 1000 muestras y nuestro modelo es capaz de clasificar bien 990 de ellas entonces, el valor de *accuracy* es del 99 %.

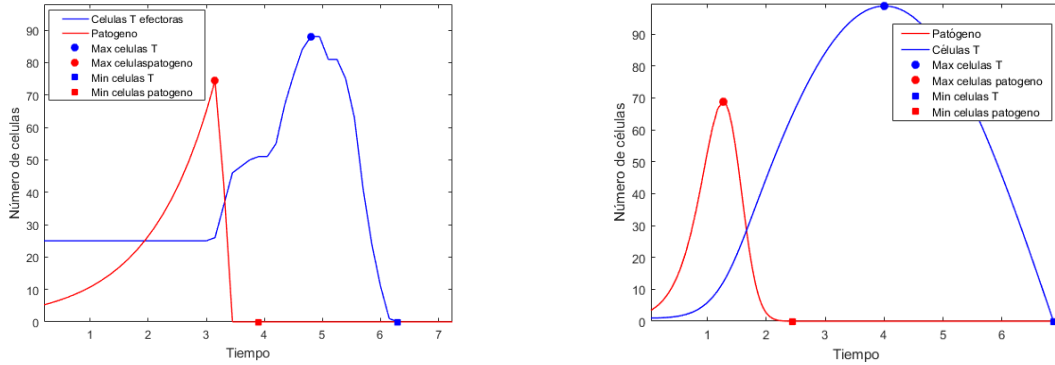
En la Figura 6.2 podemos ver las gráficas correspondientes a los valores de *loss* y *accuracy* durante el entrenamiento de la red. Como se puede observar en la Figura 6.2a, el valor de *loss* consigue estabilizarse al mínimo en el conjunto de prueba una vez pasada la iteración 230 (ver Figura 6.2a). Por su parte, el valor de *accuracy* (ver Figura 6.2b) continúa incrementándose para el conjunto de entrenamiento hasta prácticamente la última iteración, lo que indica que el modelo no está sobreentrenando, a pesar de que en el conjunto de prueba se estabilice una vez pasada la iteración 100 aproximadamente. Estos resultados sugieren que el número de *epoch* utilizados para entrenar la red es el óptimo.

En el archivo *resultados.txt* se pueden ver algunos de los resultados obtenidos por la red, correspondientes a distintos valores de *accuracy*<sup>5</sup>.

### 6.2.1. Ejemplo de ejecución de la red

En el caso que nos ocupa ahora, detallaremos un ejemplo concreto obtenido a partir de los datos de una simulación del modelo microscópico, cumpliendo así con el propósito de esta red. En la Figura 6.3a podemos ver el resultado de la simulación del modelo microscópico, con los seis puntos de interés destacados. Concretamente el valor de esos parámetros es:  $max\_P = 74,4$ ,  $max\_T = 88$ ,  $t\_max\_P = 3,15$ ,  $t\_max\_T = 4,8$ ,  $t\_min\_P = 3,9$  y  $t\_min\_T = 6,3$ . Una vez la red estaba entrenada se introdujeron estos valores como entrada para obtener la predicción de los valores de los parámetros del modelo macroscópico.

<sup>5</sup>El resultado de cada de las distintas simulaciones se representa por filas con el siguiente formato: [los seis puntos de interés generados tras una simulación del modelo microscópico] => [el valor predicho por la red para los parámetros  $\alpha$ ,  $\beta$ ,  $k$  y  $\lambda$ ] (expected [el valor real de dichos parámetros]).



(a) Simulación: caso de intolerancia al patógeno en el modelo microscópico. Parámetros y variables:  $t_{cycle} = 0,05$ ,  $t_{apo} = 0,1$ ,  $t_{next} = 0,15$ ,  $\alpha = 6,4$ ,  $\beta = 0,22$ ,  $\lambda_{pd} = 0,05$ ,  $\lambda_{Tp} = 6 * 10^{-5}$ ,  $\lambda_{pp} = 0,5 * 10^{-4}$ ,  $\mu_{pc} = 8$ ,  $\mu_{da} = 15$ .

(b) Simulación: caso de intolerancia al patógeno en el modelo macroscópico. Parámetros:  $\alpha = 3,5$ ,  $\beta = 0,29$ ,  $k = 0,3$ ,  $\lambda = 0,9$ ,  $P_m = 0$ .

Figura 6.3: Ejemplo con simulaciones del modelo microscópico y macroscópico con los valores de los parámetros predichos por la red neuronal. Casos de intolerancia al patógeno.

El resultado obtenido fue:  $\alpha = 3,5$ ,  $\beta = 0,29$ ,  $k = 0,3$  y  $\lambda = 0,9$ . En la Figura 6.3b puede verse la simulación del modelo macroscópico correspondiente a esos parámetros. Si comparamos ambas figuras observamos a simple vista que ambas presentan dos situaciones muy similares, si bien es cierto que los valores difieren ligeramente. En particular, la simulación del modelo macroscópico tiene en puntos de interés los siguientes valores:  $max\_P = 68,94$ ,  $max\_T = 98,82$ ,  $t\_max\_P = 1,27$ ,  $t\_max\_T = 4$ ,  $t\_min\_P = 2,45$  y  $t\_min\_T = 6,87$ . Si comparamos estos valores con los obtenidos con el modelo microscópico vemos que el valor  $max\_P$  es menor en el modelo microscópico pero que los tiempos asociados a este ( $t\_max\_P$  y  $t\_min\_P$ ) también lo son. Esto nos dice que, a pesar de que los valores no han sido exactos, la forma de la gráfica sí se preserva. Si prestamos atención a los valores referentes a las células T, vemos que el patrón ha cambiado, pues se alcanza un número mayor de células T en el modelo macroscópico y, sin embargo, este valor se alcanza antes que en el modelo microscópico. Esto nos indica que los parámetros de elasticidad e inercia no se han ajustado completamente, lo que hace que observemos ese pequeño desfase.





## Conclusiones y Trabajo Futuro

Los estudios recogidos en este documento muestran la utilidad de los métodos matemáticos para proponer modelos que no solo se limiten a reproducir hechos observados, sino que sean capaces de sugerir explicaciones de los mismos y permitan formular predicciones que puedan ser verificadas, o descartadas, experimentalmente.

Los modelos propuestos en los Capítulos 3 y 5 se presentan como posibles explicaciones a un mecanismo biológico de gran interés y conocido solo parcialmente, como es la dinámica de población de las células T durante una infección aguda. Ambos modelos están bien fundamentados, pues sus hipótesis están basadas en evidencias biológicas. Gracias a estos modelos somos capaces de reproducir y predecir el comportamiento de las células T durante una infección aguda en distintas situaciones mediante la variación del valor de sus parámetros, sin necesidad de costosos experimentos y desde dos puntos de vista diferentes, el microscópico y el macroscópico. Por otro lado, ambos son modelos abiertos a la inclusión de nuevo conocimiento biológico.

Del modelo microscópico destacamos su contraposición a la hipótesis de que el desarrollo de la vida de una célula T viene determinado por la *estimulación antgénica* recibida durante su activación. De esta manera, las células generadas en la *expansión clonal* tendrían un control muy limitado sobre su elección entre división o apoptosis. Sin embargo, el modelo propuesto expone que los encuentros de una célula T con el *antígeno* son transmitidos a las células hijas por medio de receptores de membrana, que se reparten durante la división celular. Esto permite a las nuevas células integrar este conocimiento con su propia experiencia con el *antígeno*, posibilitando que células que comparten un mismo ancestro tomen decisiones distintas. Con ello, se pone de manifiesto que la heterogeneidad de decisiones observada durante una *respuesta inmune* puede ser explicada mediante un algoritmo determinista e independientemente ejecutado por las células T. La respuesta que dan las células T es específica para un *antígeno*, pero no para un patógeno<sup>1</sup>. Esto explica el hecho de que los mecanismos de reconocimiento de patógenos no se detallen en el modelo, dotando al mismo de capacidad de adaptación a distintas estrategias de infección (Arias et al., 2014).

Por su parte, el modelo macroscópico observa la dinámica de población de las células T (*expansión y contracción clonal*) de manera colectiva. Para ello modeliza su comportamiento mediante ecuaciones diferenciales de segundo orden, sustentadas por dos propiedades poblacionales: la elasticidad y la inercia. Este modelo arroja resultados interesantes. En

---

<sup>1</sup>Un *antígeno* específico puede estar presente en diversos patógenos, que pueden ser muy heterogéneos en términos de tasas de crecimiento o mecanismos de escape ante la *respuesta inmune*.

concreto, propone que el mecanismo de identificación de la población objetivo de las células T viene determinada por la tasa de crecimiento de esta. Es decir, aquellas poblaciones que crecen muy rápidamente son consideradas como patógenos, mientras que aquellas que poseen tasas de crecimiento reducidas son toleradas. Esta propuesta es compatible con el hecho paradójico de que un crecimiento lento sea la estrategia de evasión de algunas células tumorales o virus como el de la hepatitis C (Crawford y Wherry, 2010; Tomov et al., 2013).

Otra cuestión que consideramos particularmente relevante es la planteada en el Capítulo 6. En este se buscaba establecer una correspondencia entre los parámetros de los dos modelos vistos en los capítulos anteriores, puesto que ambos muestran comportamientos poblacionales compatibles. El modelo microscópico se caracteriza por representar características biológicas explícitas de las células mediante parámetros estructurales, cuyo valor permanece fijo durante la simulación. Sin embargo, el significado de los parámetros del modelo macroscópico, referentes a las características de inercia y elasticidad de la población de células T, carecen de un significado biológico claro. A pesar de ello, una de las ventajas de este modelo es el reducido número de parámetros que tiene. Es por ello que encontrar una correspondencia de parámetros entre ambos modelos sería de gran utilidad, por ejemplo, para determinar los parámetros del modelo microscópico que se corresponden con una cierta *respuesta inmune*<sup>2</sup>. A lo largo del Capítulo 6 se detalla una primera aproximación para la resolución de esta compleja cuestión. Los resultados obtenidos por la red neuronal son prometedores, pero aún insuficientes para poder deducir una correspondencia formal entre ambos modelos. Esperamos profundizar este estudio en un próximo futuro.

---

<sup>2</sup>De esta manera, la respuesta podría simularse utilizando el modelo macroscópico, cuyos parámetros son más fáciles de ajustar y, posteriormente, establecer los correspondientes parámetros en el modelo microscópico, los cuales son fácilmente interpretables.

## Introduction

The year 2018 was proclaimed International Year of Mathematical Biology by two scientific societies: the European Mathematical Society (EMS) and the European Society for Mathematical and Theoretical Biology (ESMTB). This celebration intended to highlight the importance of the applications of mathematics to biology and life sciences and to encourage their interaction<sup>1</sup>. Today, life sciences are increasingly using mathematics, ranging from the use of dynamic systems and statistics to population and disease spread models. In this context, models play an important role, as they are simplified representations of the structure and functioning of a given biological system or process, using mathematical language to express the relationships between variables<sup>2</sup>. The appropriate use of models allows us to advance beyond what mere intuition suggests and provides us with useful information that would otherwise be difficult to collect, either because of the high economic cost of the experiments, the time it takes to carry them out or the amount of data to be examined, among other reasons. But it is not only experts who benefit from the simplifying power of mathematical models. During the current COVID-19 health crisis, mathematical models have been used to predict the spread of the virus and to inform society of the risk of this pandemic<sup>3</sup>.

Throughout this document, we will focus on the field of immunology. It is interesting to note that the cells that make up the immune system are not regulated by a coordinating organ (Arias y Herrero, 2016). Immune cells move freely through the body and lead an independent life. However, they are capable of displaying collective behaviour, as is the case with the response to infectious agents. In this defensive function, T cells play a very important role. When an infection is detected, the population of this type of cells grows by several orders of magnitude in a few days and, once the infectious agent has disappeared, population levels are restored through the suicide (apoptosis) of a large part of the population generated. The decision mechanism between division or apoptosis taken by T cells during the immune response still has many questions. In the following chapters, we will present two mathematical models, based on differential equations, which attempt to shed light on this phenomenon. The first one, which can be seen in the Chapter 3, deals with this issue from a microscopic point of view. That is, it proposes a decision algorithm implemented by each cell. Meanwhile, the equations of the second model, set out in the Chapter 5, describe the dynamic behaviour of the entire population of T cells, based on two

<sup>1</sup>[https://www.icmat.es/divulgacion/Material\\_Divulgacion/miradas\\_matematicas/06.pdf](https://www.icmat.es/divulgacion/Material_Divulgacion/miradas_matematicas/06.pdf)

<sup>2</sup><http://www.blogsanidadanimal.com/2018-el-ano-internacional-de-la-biologia-matematica/>

<sup>3</sup>Mathematical models on COVID-19 growth curve in *The Washington Post*: <https://www.washingtonpost.com/graphics/2020/world/corona-simulator/>

main characteristics attributed to that population: elasticity and inertia. In both cases, numerical simulations of these models are performed. These simulations represent different situations that can occur during infection. Among them, it is interesting to distinguish between the situation of intolerance to the pathogen, in which case the immune cells manage to control the infection and eliminate the infectious agent, or the situation of tolerance to the pathogen, in which it is the latter who ends up taking control of the organism. It also discusses what happens when we have populations of T cells with different affinities to the pathogen. The relationship between the properties of both models is an interesting topic, which is addressed in the last chapter (Chapter 6). As we will see, both give rise to results that are not only compatible but complementary.

## 8.1. Objectives

This Final Project focuses on the study of the population dynamics of T cells in the face of acute infection and, more specifically, on the study of two mathematical models that aim to respond to the mechanisms that govern this behaviour.

To approach this project, the following objectives were determined:

- Study of the basics of the immune system, focusing on the role that T cells play during an *immune response*.
- Study and understanding of the mathematical models detailed in this document and their importance in the field of biology.
- Implementation of the code needed to simulate different T cell behaviours based on these models and analysis of these behaviours.
- Obtaining a first approximation to establish a correspondence between the parameters of the two models studied.

## 8.2. Work plan

To carry out this work, various milestones were established throughout the academic year. The first months were devoted to a prior review of the underlying biological concepts. These included basic notions about the immune system and a more detailed study of T cell behaviour. This constitutes a fundamental part of the work, as the models cannot be fully understood if they are not looked at from the biological problem to which they are trying to respond. Once the biological basis was established, the study of the models could begin. The first one to be studied would be the microscopic model shown in Arias et al. (2014). Different simulations of the model were established, which would complement the theory seen. The second model, the macroscopic model (Arias et al., 2015), would be studied later, with the purpose of being able to relate it to the previous one.

Once both models had been reviewed and the corresponding simulations had been carried out, the possibility was opened up of trying to establish a correspondence between the parameters of both models by implementing a neural network. The latter would put an end to the content of this Bachelor's theses.

## 8.3. Document structure

This work is divided into four well-differentiated parts, but with the same purpose, the study of T cells and their population dynamics during an acute infection.

1. The context of the document is covered in Chapter 2. In particular, Section 2.1 covers basic notions of immunology, which allows the reader to proceed through the following chapters without any terminological impediment, as far as biological issues are concerned. This section is intended to give a very basic overview of the immune system. It starts with the simplest mechanisms, referring to the *innate immune system* (Section 2.1.1), to the most complex ones, referring to the *adaptive immune system* (Section 2.1.2). The aspects of the immune response involving T cells, such as their activation and performance or immune memory, are discussed in more detail (Section 2.1.2.1).

Furthermore, Section 2.2 deals with the role of mathematical models in the field of biology. Specifically, in Section 2.2.1, we focus on the case of our study, the different mathematical models formulated for the dynamics of T cells during an acute infection.

2. The theoretical framework of the proposed microscopic model for the problem of deciding between T cell division and apoptosis is presented in Chapter 3. In Section 3.1 the biological hypotheses on which the model is based are detailed. Those hypotheses constitute contrasted and observed facts in the field of biology. The model itself can be seen in Section 3.2, which details the notation that will be followed by the rest of the document and the first-order differential equations that give rise to the algorithm. The last section of this chapter, Section 3.3, introduces a differential equation for the population dynamics of the pathogen and its relationship to the number of available T cells. The equation establishes the interaction between the two populations.

In Chapter 4 the simulations corresponding to a simplified case of the previous model are presented (Section 4.1) and the basic details of its implementation are explained (Section 4.2). The results of the simulations are described in Section 4.3. These simulations correspond to cases of intolerance and tolerance to the pathogen (Sections 4.3.1 and 4.3.2, respectively), as well as the case of the immune response with populations of T cells with different affinities to the pathogen (Section 4.3.3).

3. The macroscopic model is studied in Chapter 5. The second-order differential equations of this model govern the population dynamics of T cells and the pathogen collectively, unlike the microscopic model, whose algorithm was defined for each cell. This model is based on two characteristics of the T cell population behaviour during an immune response: elasticity and inertia (Section 5.1).

In addition to proposing a theoretical model, the numerical simulations corresponding to the model are also carried out in Section 5.2. These include the cases of intolerance and tolerance to the pathogen (Sections 5.2.1 and 5.2.2, respectively) and, for the macroscopic non-dimensional model, the relevance of the value of its two parameters in the regions of tolerance and intolerance is studied (Section 5.2.3).

4. Then, after studying the models proposed in Chapters 3 and 5, and after comparing their results, a parameter correspondence is sought between both models in Chapter 6. For this purpose, a neural network which is capable of performing “the inverse

function” to the code referring to the simulations of the macroscopic model is implemented. That is to say, given the results of a simulation, the network can predict the value of the parameters necessary to obtain that same result. The construction of the dataset and the implementation of the network can be seen in the Section 6.1. The results obtained and an example of execution, using as input the results of a simulation of the microscopic model, can be seen in the Section 6.2.

Finally, Chapter 9 offers a brief conclusion of the work carried out. To complement the project, the main code of the model simulations (both those of Chapter 4 and 5) has been included in Appendix A.

## Conclusions and Future Work

The studies collected in this document show the usefulness of mathematical methods in proposing models that not only reproduce observed facts but are also capable of suggesting explanations for them and make it possible to formulate predictions that can be verified, or discarded, experimentally.

The models proposed in Chapters 3 and 5 are presented as possible explanations to a biological mechanism of great interest and only partially known, such as the population dynamics of T cells during an acute infection. Both models are well-founded, as their hypotheses are based on biological evidence. Thanks to these models we can reproduce and predict the behaviour of T cells during acute infection in different situations by varying the value of their parameters, without the need for expensive experiments and from two different points of view, the microscopic and the macroscopic. On the other hand, both are models open to the inclusion of new biological knowledge.

From the microscopic model, we highlight its contrast to the hypothesis that the life of a T cell is determined by the *antigenic stimulation* received during its activation. In this way, the cells generated in the *clonal expansion* would have very limited control over their choice between division or apoptosis. However, the proposed model states that the encounters of a T cell with the *antigen* are transmitted to the daughter cells using membrane receptors, which are distributed during cell division. This allows new cells to integrate this knowledge with their own experience with the *antigen*, enabling cells that share the same ancestor to make different decisions. This shows that the heterogeneity of decisions observed during an immune response can be explained by a deterministic algorithm and can be independently executed by the T cells. The response given by T cells is specific to an *antigen*, but not to a pathogen<sup>1</sup>. This explains the fact that the mechanisms of pathogen recognition are not detailed in the model, giving it the capacity to adapt to different infection strategies (Arias et al., 2014)

Meanwhile, the macroscopic model observes the population dynamics of T cells (*clonal expansion* and *contraction*) collectively. It, therefore, models their behaviour using second-order differential equations, based on two population properties: elasticity and inertia. This model yields interesting results. Specifically, it proposes that the mechanism of identification of the target population of T cells is determined by the growth rate of the T cell. In other words, those populations that grow rapidly are considered to be pathogenic, while those with reduced growth rates are tolerated. This proposal is compatible with the para-

---

<sup>1</sup>A specific *antigen* may be present in several pathogens, which may be very heterogeneous in terms of growth rates or escape mechanisms from the *immune response*.

doxical fact that slow growth is the avoidance strategy of some tumour cells or viruses such as hepatitis C (Crawford y Wherry, 2010; Tomov et al., 2013).

Another question that we consider particularly relevant is the one raised in Chapter 6. In this chapter, we sought to establish a correspondence between the parameters of the two models seen in the previous chapters, since both show compatible population behaviour. The microscopic model is characterized by representing explicit biological characteristics of the cells by means of structural parameters, whose value remains fixed during the simulation. However, the meaning of the parameters of the macroscopic model, referring to the characteristics of inertia and elasticity of the T cell population, lacks a clear biological meaning. Nevertheless, one of the advantages of this model is the reduced number of parameters it has. Therefore, finding a parameter correspondence between the two models would be very useful, for example, to determine the parameters of the microscopic model that correspond to a certain *immune response*. In this way, the response could be simulated using the macroscopic model, whose parameters are easier to adjust and subsequently establish the corresponding parameters in the microscopic model, which are easily interpreted. A first approximation to the resolution of this complex question is detailed in Chapter 6. The results obtained by the neural network are promising, but still insufficient to deduce a formal correspondence between both models. We hope to deepen this study in the near future.



# Bibliografía

- ARIAS, C. F. y HERRERO, M. A. Emergent behaviour in t cell immune response. En *European Consortium for Mathematics in Industry*, páginas 17–23. Springer, 2016.
- ARIAS, C. F., HERRERO, M. A., ACOSTA, F. J. y FERNANDEZ-ARIAS, C. A mathematical model for a t cell fate decision algorithm during immune response. *Journal of Theoretical Biology*, vol. 349, páginas 109 – 120, 2014. ISSN 0022-5193.
- ARIAS, C. F., HERRERO, M. A., CUESTA, J. A., ACOSTA, F. J. y FERNÁNDEZ-ARIAS, C. The growth threshold conjecture: a theoretical framework for understanding t-cell tolerance. *Royal Society open science*, vol. 2(7), página 150016, 2015.
- CASTRO, M., LYTHER, G., MOLINA-PARÍS, C. y RIBEIRO, R. M. Mathematics in modern immunology. 2016.
- CRAWFORD, A. y WHERRY, E. J. Unravelling cd4 t cell dysfunction during chronic infection (39.17). *The Journal of Immunology*, vol. 184(1 Supplement), páginas 39.17–39.17, 2010. ISSN 0022-1767.
- DUFFY, K. R. y HODGKIN, P. D. Intracellular competition for fates in the immune system. *Trends in Cell Biology*, vol. 22(9), páginas 457 – 464, 2012. ISSN 0962-8924.
- FERNÁNDEZ ARIAS, C. *Mecánica de poblaciones celulares elásticas: ecología de la respuesta inmunitaria*. Tesis Doctoral, Universidad Complutense de Madrid, 2012.
- GUNAWARDENA, J. Models in biology: ‘accurate descriptions of our pathetic thinking’. *BMC Biology*, vol. 12, 2014. ISSN 1741-7007.
- HAWKINS, E. D., TURNER, M. L., DOWLING, M. R., VAN GEND, C. y HODGKIN, P. D. A model of immune regulation as a consequence of randomized lymphocyte division and death times. *Proceedings of the National Academy of Sciences*, vol. 104(12), páginas 5032–5037, 2007. ISSN 0027-8424.
- LEGGETT, H. C., CORNWALLIS, C. K., BUCKLING, A. y WEST, S. A. Growth rate, transmission mode and virulence in human pathogens. *Philosophical Transactions of the Royal Society B: Biological Sciences*, vol. 372(1719), página 20160094, 2017.
- SOMPAYRAC, L. *How The Immune System Works*. Versión electrónica, 2016.
- TABORDA, N. A., HERNÁNDEZ, J. C., MONTOYA, C. J. y RUGELES, M. T. Las células natural killer y su papel en la respuesta inmunitaria durante la infección por el virus de la inmunodeficiencia humana tipo-1. 2014.

TOMOV, V. T., OSBORNE, L. C., DOLFI, D. V., SONNENBERG, G. F., MONTICELLI, L. A., MANSFIELD, K., VIRGIN, H. W., ARTIS, D. y WHERRY, E. J. Persistent enteric murine norovirus infection is associated with functionally suboptimal virus-specific CD8 T cell responses. *J. Virol.*, vol. 87(12), páginas 7015–7031, 2013.

# Apéndice A

## Código de las simulaciones

En este apéndice se expone el código utilizado para las simulaciones de los dos modelos vistos en este trabajo, el microscópico y el macroscópico, correspondientes al Capítulo 4 y Capítulo 5, respectivamente. El código, realizado en Matlab, sigue la misma notación que se establece en los capítulos correspondientes.

### A.1. Código referente al Capítulo 4

En esta sección se expone el código principal de las simulaciones vistas en el Capítulo 4. El código que sigue corresponde a la Figura 4.1a donde puede verse el caso de intolerancia al *patógeno*. Para la simulación del caso de tolerancia, que aparece en la Figura 4.1b, el código es exactamente el mismo aunque varía el valor de los parámetros, como ya se expuso en la correspondiente figura.

Para el caso de las figuras correspondientes a varias poblaciones de células T (Figura 4.2a - Figura 4.2c) la idea que subyace es similar, simplemente se añadieron los correspondientes parámetros y estructuras para guardar la acción de cada una de las poblaciones de células T.

Las funciones *sys\_4\_1\_sol* y *sys\_4\_2\_sol* dan el resultado de la solución explícita de los sistemas 4.1 y 4.2, respectivamente, evaluada en los parámetros que se pasan a la función. La estructura *t\_cell\_matrix* es una matriz que almacena en cada fila una célula de la población y cuyas columnas guardan los parámetros correspondientes a esa célula (su tipo, condiciones iniciales, número de receptores y el tiempo que le queda para completar la fase de ciclo o apoptosis, en caso de que se encuentre en alguna de ellas).

```
1 %This code is desgined to simulate system 4.1. Intolerance case.
2 %By Belen Serrano Anton
3 %Created 25/02/2020
4 %Last Modified 31/03/2020
5
6 %Variable definition
7 t_cycle = 0.15; %Time lap between the restriction point and cell division
8 t_apo = 0.2; %Time lap between the deactivation of Bcl-2 and cell death
9 t_next = 0.3; %Time step in this simulation
10
11 %Parameters: Pathogen
12 alpha = 6; %Pathogen proliferation rate
13 beta = 0.04; %Pathogen death rate
14
```

```

15 %Parameters: Effector T cells
16 lambda_pd = 0.05; %Change rate in membrane receptor Rd, due to Rp signals
17 lambda_taup = 6*10−5; %Change rate in membrane receptor Rd, due to TCR signals
18 lambda_pp = 0.5*10−4; %Change rate in membrane receptor Rp, due to Rp signals
19 mu_pc = 15; %Change rate in inhibitor molecule Rb, due to receptor Rc
20 mu_da = 10; %Change rate in inhibitor molecule Bcl-2, due to receptor Rc
21
22 %Parameters: Memory T cells
23 lambda_pd_mem = 0; %Change in membrane receptor Rd, due to Rp signals
24 lambda_taup_mem = 10−5; %Change rate in membrane receptor Rd, due to TCR
    signals
25 lambda_pp_mem = 2*10−2; %Change rate in membrane receptor Rp, due to Rp signals
26 mu_pc_mem = 13; %Change rate in inhibitor molecule Rb, due to receptor Rc
27
28 %Define the final time we will simulate to
29 T_final = 25;
30
31 %Define the initial number of particles
32 N_init = 0; %N will represent T cells
33 Y_init = 5; %Y will represent pathogen
34
35 %Define how long the recording vectors should be
36 num_rec_steps = round(T_final/t_next);
37
38 %Initialise the index which will tell us where to write the current values
39 rec_ind=1;
40
41 %Define the maximum number of t cells
42 num_max_cells=107;
43
44 %Instantiate a vector which will hold the time varying values of T cells
45 %and pathogen
46 rec_vector_N_eff = -ones(1,num_rec_steps); %For effector T cells
47 rec_vector_N_mem = -ones(1,num_rec_steps); %For memory T cells
48 rec_vector_Y = -ones(1,num_rec_steps); %For the pathogen
49
50 %Write the initial condition to these vectors
51 rec_vector_N_eff(rec_ind) = N_init; %Asymmetric division of naive T cells
52 rec_vector_N_mem(rec_ind) = N_init; %Asymmetric division of naive T cells
53 rec_vector_Y(rec_ind) = Y_init;
54
55 %Instantiate a vector which will hold the t cells
56 t_cell_matrix=zeros(num_max_cells,6);
57
58 %Write the initial condition to this vector
59 a0 = 0.3;
60 c0 = 0.08;
61 c0_mem = 0.04;
62
63 t_cell_matrix(1:2:2*N_init,1)=1; %type 1: Effector T cell
64 t_cell_matrix(1:2:2*N_init,2)=a0;
65 t_cell_matrix(1:2:2*N_init,3)=c0;
66
67 t_cell_matrix(2:2:2*N_init,1)=2; %type 2: Memory T cell
68 t_cell_matrix(2:2:2*N_init,3)=c0_mem;
69

```

```

70
71 %Initialise a vector which will hold the times when reactions occur
72 time_vec=zeros(1,num_rec_steps);
73
74 %Initialise the number of particles for this repeat
75 N_eff = N_init;
76 N_mem = N_init;
77 N = N_eff + N_mem;
78 Y = Y_init;
79
80 %Initialise index for t_cell_matrix
81 rec_ind_tcell_matrix = N+1;
82
83 %Define the initial time to be zero
84 t=0;
85
86 %Gone is true if the pathogen is dead and false otherwise
87 gone = 0;
88
89 while t < T_final
90
91     %Increase the recording index
92     rec_ind=rec_ind+1;
93
94     if(gone==0)
95         %Calculate Y
96         Y = Y_init*exp(t*(alpha - N_eff*beta));
97         Y = max(Y,0);
98         if(Y < 10^(-6)) %condition that states when the pathogen is defeated
99             Y = 0;
100             gone = 1;
101         end
102     end
103
104     %Fate decision for each T cell
105     %Initialise indexes
106     nCell=1;
107     ind_N = 1;
108
109     while nCell < rec_ind_tcell_matrix
110         v_rand = rand(N,1)/N; %vector of N random numbers
111
112         if(t_cell_matrix(nCell,1) == 1 || t_cell_matrix(nCell,1) == 2)
113             rho = v_rand(ind_N);
114             r_tau=rho*Y;
115             ind_N = ind_N + 1;
116         end
117
118         %Killer T cell
119         if(t_cell_matrix(nCell,1) == 1 || t_cell_matrix(nCell,1) == 3)
120             if(t_cell_matrix(nCell,6) > 0)
121                 %In division phase
122                 t_cell_matrix(nCell,6) = max(t_cell_matrix(nCell,6)-t_next,0);
123
124                 %Division phase completed
125                 if(t_cell_matrix(nCell,6) == 0 && t_cell_matrix(nCell,1) == 3)

```

```

126         N_eff = N_eff + 1;
127         t_cell_matrix(nCell,1) = 1;
128     end
129 else
130     %Initial conditions
131     p0_sys = t_cell_matrix(nCell,4);
132     d0_sys = t_cell_matrix(nCell,5);
133     c0_sys = t_cell_matrix(nCell,3);
134     a0_sys = t_cell_matrix(nCell,2);
135
136     %Explicit solutions for system 4.1
137     [c,a,p,d] = sys_4_1_sol(t,lambda_taup,lambda_pp,r_tau,p0_sys,
        lambda_pd,d0_sys,mu_pc,c0_sys,mu_da,a0_sys);
138
139     %Desision state
140     if( a > 0 && c > 0)
141         d=max(d,0);
142         p=max(p,0);
143         t_cell_matrix(nCell,4) = p;
144         t_cell_matrix(nCell,5) = d;
145         t_cell_matrix(nCell,3) = c;
146         t_cell_matrix(nCell,2) = a;
147     else
148         if(a <= 0) %Initiate apoptosis
149             t_cell_matrix(nCell,6) = t_apo;
150             t_cell_matrix(nCell,1) = 4;
151
152         elseif(c <= 0) %Initiate division
153             %Membrane receptors are divided between 2 daughter
154             %cells
155             delta_P_child_1 = 0.4+(0.6-0.4)*rand();
156             delta_P_child_2 = 1 - delta_P_child_1;
157             delta_D_child_1 = 0.4+(0.6-0.4)*rand();
158             delta_D_child_2 = 1 - delta_D_child_1;
159
160             r_p_child_1 = delta_P_child_1 * p;
161             r_p_child_2 = delta_P_child_2 * p;
162
163             r_d_child_1 = delta_D_child_1 * d;
164             r_d_child_2 = delta_D_child_2 * d;
165
166             %Actualization for daughter cells
167             t_cell_matrix(nCell,4) = r_p_child_1;
168             t_cell_matrix(nCell,5) = r_d_child_1;
169             t_cell_matrix(nCell,6) = t_cycle;
170
171             t_cell_matrix(nCell,3) = c0;
172             t_cell_matrix(nCell,2) = a0;
173
174             %type 3 -> new effector cell that has not
175             %completed division phase
176             t_cell_matrix(rec_ind_tcell_matrix,1) = 3;
177             t_cell_matrix(rec_ind_tcell_matrix,4) = r_p_child_2;
178             t_cell_matrix(rec_ind_tcell_matrix,5) = r_d_child_2;
179             t_cell_matrix(rec_ind_tcell_matrix,6) = t_cycle;
180

```

```

181         t_cell_matrix(rec_ind_tcell_matrix,3) = c0;
182         t_cell_matrix(rec_ind_tcell_matrix,2) = a0;
183
184         %Increase index for the next new cell
185         rec_ind_tcell_matrix = rec_ind_tcell_matrix + 1;
186     end
187 end
188
189 %Next cell in population
190 nCell = nCell + 1;
191
192 %Memory T cell
193 elseif(t_cell_matrix(nCell,1) == 2 || t_cell_matrix(nCell,1) == 5)
194     if(t_cell_matrix(nCell,6) > 0)
195         %In division phase
196         t_cell_matrix(nCell,6) = max(t_cell_matrix(nCell,6)-t_next,0);
197
198         %Division phase completed
199         if(t_cell_matrix(nCell,6)==0 && t_cell_matrix(nCell,1) == 5)
200             N_mem=N_mem+1;
201             t_cell_matrix(nCell,1) =2;
202         end
203     else
204         %Initial conditions
205         c0_solsys =t_cell_matrix(nCell,3);
206         p0_solsys =t_cell_matrix(nCell,4);
207
208         %Explicit solutions for system 4.2
209         [c,p] = sys_4_2_sol(t,mu_pc_mem, p0_solsys, lambda_taup_mem,
210             lambda_pp_mem, r_tau, c0_solsys);
211
212         %Division phase
213         if(c <= 0)
214             delta_P_child_1 = 0.4+(0.6-0.4)*rand();
215             delta_P_child_2 = 1 - delta_P_child_1;
216
217             r_p_child_1 = delta_P_child_1 * p;
218             r_p_child_2 = delta_P_child_2 * p;
219
220             t_cell_matrix(nCell,4)=r_p_child_1;
221             t_cell_matrix(nCell,6)=t_cycle;
222
223             t_cell_matrix(nCell,3) = c0_mem;
224
225             t_cell_matrix(rec_ind_tcell_matrix,1)=5;
226             t_cell_matrix(rec_ind_tcell_matrix,4)=r_p_child_2;
227             t_cell_matrix(rec_ind_tcell_matrix,6)=t_cycle;
228
229             t_cell_matrix(rec_ind_tcell_matrix,3)=c0_mem;
230
231             rec_ind_tcell_matrix = rec_ind_tcell_matrix + 1;
232         else
233             t_cell_matrix(nCell,4)=p;
234             t_cell_matrix(nCell,3)=c;
235         end

```

```

236         end
237
238         nCell=nCell+1;
239
240
241         elseif(t_cell_matrix(nCell,1) == 4) %Effector T cell is dead
242
243             if(t_cell_matrix(nCell,6) > 0)
244                 t_cell_matrix(nCell,6) = max(t_cell_matrix(nCell,6)-t_next,0);
245                 if(t_cell_matrix(nCell,6)==0)
246                     N_eff=N_eff-1;
247                 end
248             end
249             nCell=nCell+1;
250         else
251             break;
252         end
253
254     end
255
256     %Update the time
257     t=t+t_next;
258
259     %Record the time and the numbers of molecules
260     time_vec(rec_ind) = t;
261     N = N_eff + N_mem;
262     rec_vector_N_eff(rec_ind) = N_eff;
263     rec_vector_N_mem(rec_ind) = N_mem;
264     rec_vector_Y(rec_ind) = Y;
265 end
266
267 %Plot results
268 f1=figure;
269
270 figure(f1)
271 [hA1]=plot(time_vec,rec_vector_N_eff/max(rec_vector_N_eff),'b','LineWidth', 1);
272
273 hold on
274 [hA2]=plot(time_vec,rec_vector_Y/max(rec_vector_Y),'r','LineWidth', 1);
275
276 hold on
277 %[hA3] = plot(time_vec,rec_vector_N_mem/max(rec_vector_N_eff),'g','LineWidth', 1);
278
279 set(gca,'YTickLabel',[]);
280 set(gca,'XTickLabel',[]);
281
282 legend([hA1,hA3,hA2],'Celulas T efectoras','Celulas T de memoria','Patogeno');
283 xlabel('Tiempo'); ylabel('Numero de celulas');

```

## A.2. Código referente al Capítulo 5

En esta sección veremos el código correspondiente al modelo macroscópico. En esta ocasión no disponíamos de un sistema de ecuaciones diferenciales con solución explícita, por



lo que implementamos las simulaciones numéricas mediante el uso de la función *ode\_45*<sup>1</sup> de Matlab. A continuación podemos ver el código referente a la Figura 5.1, en el que se modela el Sistema 5.1.

Para simular la Figura 5.2b, correspondiente al caso de tolerancia, se tomó el Sistema 5.2, el código sigue la misma estructura aunque las ecuaciones que vemos en las líneas 24 y 25 sufren una ligera modificación: los parámetros  $k$  y  $\lambda$  desaparecen y se sustituyen  $a$  ( $\alpha$ ) y  $b$  ( $\beta$ ) por los correspondientes  $a\_star$  ( $\alpha^*$ ) y  $b\_star$  ( $\beta^*$ ) del Sistema 5.2.

```

1 %This code is desgined to simulate system 5.1.
2 %By Belen Serrano Anton
3 %Created 03/03/2020
4 %Last Modified 31/03/2020
5
6 syms t __cell(t) p(t)
7
8 %Constants
9 a = 1.5;
10 b = 0.1;
11
12 k = 0.4;
13 lambda = 0.5;
14
15 t0 = 0;
16 tf = 10;
17 dt __cell=diff(t __cell,t);
18
19 %Initial Conditions
20 c1 = 3; %P(0)
21 c2 = 0; %T(0)
22 c3 = 0; %T'(0)
23 y0 = [c1 c2 c3];
24 eq1 = diff(t __cell,t,2) == -k*t __cell + lambda*p;
25 eq2 = diff(p,t) == a*p - b*t __cell*p;
26
27 vars = [t __cell(t); p(t)];
28 [V,S] = odeToVectorField([eq1,eq2]);
29
30 M = matlabFunction(V,'vars', {'t','Y'});
31 interval = [t0 tf]; %Time interval
32 %Impose a nonnegativity constraint
33 option2 = odeset('NonNegative',2); %T >= 0
34
35
36
37 ySol = ode45(M,interval,y0, option2);
38 tValues = linspace(interval(1),interval(2),1000);
39 yValues = deval(ySol,tValues,1);
40
41 %Plot results
42 figure
43 [hA2] = plot(tValues,yValues/max(yValues),'r','LineWidth', 1); %Pathogen
44
45 hold on
46 yValues = deval(ySol,tValues,2);

```

<sup>1</sup><https://www.mathworks.com/help/matlab/ref/ode45.html>

```

47 [hA1] = plot(tValues,yValues/max(yValues),'b','LineWidth', 1); %T cells
48 ylim([0,1]);
49
50 set(gca,'YTickLabel',[]);
51 set(gca,'XTickLabel',[]);
52 xlabel('Tiempo'); ylabel('Numero de celulas');
53 legend([hA2,hA1],'Patogeno','Celulas T');

```

Veamos ahora el código de la Figura 5.3: En este caso queríamos hacer simulaciones variando el valor de los parámetros  $\alpha^*$  y  $\beta^*$ . Para ello tenemos un código que va recorriendo valores en el intervalo  $[0; 2, 5]$  y llamando con cada par de valores  $\alpha^*$  y  $\beta^*$  a la función *macro\_nond\_toler\_into* que realiza la simulación del Sistema 5.2 y devuelve si hay tolerancia o intolerancia midiendo la cantidad de *patógeno* que queda al final de la simulación. Teniendo en cuenta el resultado, se pinta un rombo rojo si estamos ante un caso de tolerancia o verde en caso de intolerancia al *patógeno*.

```

1 %This code is desgined to simulate figure 5.2.
2 %By Belen Serrano Anton
3 %Created 03/03/2020
4 %Last Modified 31/03/2020
5
6 a = 0.1;
7 b = 0.1;
8
9 f1 = figure
10
11 xlabel('\beta^{*}'); ylabel('\alpha^{*}');
12 ylim([0,2.5]);
13 xlim([0,2.5]);
14
15 while (a <= 2.5)
16     b = 0.1;
17     while(b <= 2.5)
18         %Result of system 5.2
19         res = macro_nond_toler_into(a, b);
20         figure(f1)
21         hold on
22         if(res == 1) %Intolerance
23             plot(b,a,'d','MarkerFaceColor','green', 'MarkerEdgeColor', 'green');
24         else %Tolerance
25             plot(b,a,'d','MarkerFaceColor','red', 'MarkerEdgeColor', 'red');
26         end
27         hold on
28         b = b + 0.1;
29     end
30     a = a + 0.1;
31 end

```

```

1 %This code is desgined to simulate figure 5.2.
2 %By Belen Serrano Anton
3 %Created 03/03/2020
4 %Last Modified 31/03/2020
5
6 function res = macro_nond_toler_into(a_star, b_star)
7 syms t_cell(t) p(t)
8

```

```

9
10 t0 = 0;
11 tf = 9.5;
12 dt_cell=diff(t_cell,t);
13
14 %Initial Conditions
15 c1 = 1; %P(0)
16 c2 = 0; %T(0)
17 c3 = 0; %T'(0)
18 y0 = [c1 c2 c3];
19 eq1 = diff(t_cell,t,2) == -t_cell + p;
20 eq2 = diff(p,t) == a_star*p - b_star*t_cell*p;
21
22 vars = [t_cell(t); p(t)];
23 [V,S] = odeToVectorField([eq1,eq2]);
24
25
26 M = matlabFunction(V,'vars', {'t','Y'});
27 interval = [t0 tf]; %Time interval
28
29 % Impose a nonnegativity constraint
30 option2 = odeset('NonNegative',2); %T >= 0
31
32 ySol = ode45(M,interval,y0, option2);
33 tValues = linspace(interval(1),interval(2),1000);
34 yValuesP = deval(ySol,tValues,1);
35
36 %If pathogen molecules are least than 0.01 we consider that pathogen has
37 %been totally defeated
38 if(min(yValuesP) <= 0.01)
39     res = 1; %Intolerance
40 else
41     res = 0; %Tolerance
42 end

```

